

Введение в обучение с подкреплением

Тема 1: Базовые понятия RL

Лектор: Кривошеин А.В.

Парадигмы машинного обучения

Машинное обучение (англ. Machine Learning, далее ML) —

это один из инструментов для поэтапной автоматизации решения интеллектуальных задач с помощью компьютера.

Определение ML от Т. Митчелла (автор первого учебника по ML):

компьютерная программа обучается,

если **качество решения** задач из некоторого класса задач T ,

измеренное на основе выбранной метрики Q ,

улучшается с приобретением опыта E .

Три основных парадигмы ML.

1. Обучение с учителем (англ. Supervised Learning): обобщение известного опыта (например, задачи классификации, регрессии, ранжирования).

2. Обучение без учителя (англ. Unsupervised Learning): автоматическое извлечение закономерностей из неразмеченных данных (например, задача кластеризации, снижение размерности пространства признаков).

3. Обучение с подкреплением (англ. Reinforcement Learning, далее RL): моделирование процесса принятия решений для достижения целей (например, обучение игре в шахматы, го, Starcraft и пр., управление роботом-манипулятором, беспилотным транспортом и др.)


Приложения обучения с подкреплением

AlphaGo: программа для игры в го от компании Google DeepMind, которая в 2016 году обыграла со счётом 4:1 одного из сильнейших игроков в го Ли Седоля.

AlphaGo обучалась на записанных человеческих партиях.

Улучшенная версия AlphaGo Zero обучается игре в го в ходе игр с собой. После порядка 5 млн партий AlphaGo Zero всухую обыгрывает AlphaGo.



Фильм о AlphaGo: <https://www.youtube.com/watch?v=WXuK6gekU1Y>



Боты для видео-игр: 2D игры от Atari, Quake III, Dota 2 (OpenAI Five, 2017), Starcraft 2 (AlphaStar, 2019).

Приложения обучения с подкреплением

Управление микро-климатом. Алгоритмы охлаждения дата-центров компании Google на основе RL, оценивающие систему охлаждения серверов и предсказывающие наиболее эффективные параметры для поддержания стабильной температуры и максимального энергосбережения (снижение энергопотребления до 40%).



Обучение роботов различного назначения: роботы-манипуляторы со сложным поведением, движущиеся роботы, автопилоты.

Роботы Unitree: `unitree_rl_gym`

Рекомендательные системы на основе RL. Такого типа системы, например, используются для рекомендации товаров на сайтах Alibaba Group или для рекомендаций видео на YouTube.

AlphaProof : доказательства из алгебры, анализ, теории чисел, архитектура «LLM + Верификатор Lean»

RLHF для LLM alignment

Базовые понятия и суть RL

Ключевые понятия:

окружающая **среда** (англ. **environment**)

действующий в среде **агент** (обучаемый субъект, англ. **agent**)

Агент может:

предпринимать **действия** (англ. **action**), влияющие на среду, и


принимать отклик от среды о своих действиях.

Перед агентом ставится **цель**, которая заключается в решении той или иной прикладной задачи.

Действия, которые **способствуют** достижению цели, — “хорошие” действия.

Действия, которые **препятствуют** достижению цели, — “плохие” действия.

Суть RL: научить обучаемого агента предпринимать “хорошие” последовательности действий в ходе взаимодействия со средой для эффективного достижения цели.



Базовые понятия и суть RL

Агент = Алгоритм + Устройство (которые совершают действия и принимают отклик от среды).

Агент ничего не знает о том, что мы с его “помощью” решаем какую-то внешнюю для него задачу.

Подход RL заключается в формировании системы **вознаграждений** (англ. **reward**) за действия агента.

Агент получает

положительные вознаграждения за “хорошие” действия,

отрицательные вознаграждения или штрафы за “плохие” действия.

Этот сигнал о вознаграждении и называют подкреплением (англ. **reinforcement**) по аналогии со значением этого термина в физиологии высшей нервной деятельности и психологии.

Суммарное полученное вознаграждение в ходе взаимодействия со средой называют **доходом** (англ. **gain, return**).

Вознаграждения формируются так, что

задача **достижения цели** = задача **максимизации** дохода агентом

Успешность применения методов RL к широкому кругу задач

основана на **гипотезе о вознаграждении** (англ. The Reward-is-Enough Hypothesis):

любую цель можно формализовать как задачу максимизации ожидаемого дохода.

Базовые понятия и суть RL

Как агенту понять какие действия “хорошие”?

Общая основная схема:

1. агент проводит исследование окружающей среды **методом проб и ошибок** (англ. **exploration**);
2. полученный опыт анализируется и формируется оптимальная **стратегия** (англ. **policy**) поведения;
3. агент **использует** стратегию (англ. **exploitation**) для получения максимального дохода.

Стратегия поведения агента — это набор правил о том,
какие действия агенту выбирать в различных ситуациях в среде.

Цель агента: *поиск стратегии поведения, дающей максимальный доход.*

Для описанных выше примеров задач практически невозможно составить классический алгоритм решения и только подход на основе RL позволил получить решение этих задач.

Отличие от других парадигм МО

При обучении с или без учителя обучаемый алгоритм будем также называть агентом.

При обучении с учителем:

Обучающая информация — это **инструкции** о том, какие действия правильные. Обучающий датасет должен быть сформирован до обучения и не зависит от действий агента.

При RL: Обучающая информация — это **оценка агентом** сделанных действий.

Действия влияют на ближайшее вознаграждение,
на следующее состояние среды и вознаграждение в нём,
и так далее на все следующие вознаграждения.

Этот факт называют **отложенным вознаграждением**. Правильность тех или иных действий определяется при анализе цепочки вознаграждений.

До обучения **нет готовых инструкций** о том, какие действия правильные.

Обучение **активное** — действия агента влияют на набор данных для обучения.

При обучении он-лайн данные для обучения **скоррелированы**.

У обучения без учителя и RL различны конечные цели обучения.


Обучение без учителя: нахождение структуры в неразмеченных данных;

RL: формирование оптимальной стратегии поведения.

Взаимодействие агента со средой

Схема взаимодействия агента со средой:

обучаемый агент действует в окружающей его среде, среда реагирует на действия агента.



Предполагаем, что взаимодействие агента со средой происходит в дискретные моменты времени.

1. В момент времени t , находясь в текущем состоянии среды S_t , агент производит действие A_t .
2. В момент времени $t + 1$ агент получает вознаграждение R_{t+1} , среда переходит в новое состояние S_{t+1} . В этом новом состоянии агент делает новое действие A_{t+1} и т.д.

Взаимодействие агента со средой

Под **состоянием среды** (англ. **state**) в RL может пониматься несколько различных понятий.

1. **Истинное состояние среды** (англ. world state), обычное обозначение S_t .

Полная “картина мира” среды в момент времени t (объективная реальность для агента).

2. **Наблюдение** (англ. observation), обычное обозначение O_t .

Возможно зашумленная, искаженная, неполная информация, которую сенсоры агента передают ему об истинном состоянии среды (результат субъективного восприятия для агента).

Если $S_t = O_t$, то говорят, что среда **полностью наблюдаема** (англ. fully observable).

В ином случае, среда лишь **частично наблюдаема** (англ. partially observable).

3. **Внутреннее состояние агента** (англ. internal state), обычное обозначение H_t .

Память агента, которую агент формирует самостоятельно на основе всей полученной истории наблюдений и действий.

Далее, при изложении теории по умолчанию будем считать, что среда полностью наблюдаема:

истинное состояние среды $S_t =$ наблюдение O_t .

Взаимодействие агента со средой

Общие обозначения:

S — множество состояний,

$\mathcal{A}$ — множество действий,

$\mathcal{R}$ — множество вознаграждений.

Взаимодействие агента со средой удобно записывать в виде последовательности **случайных величин**, то есть с помощью **дискретного случайного процесса**:

$$S_0, A_0, R_1, S_1, A_1, \dots$$

где S_t обозначают **состояние** среды и принимают значения в S ,

A_t обозначают **действия** агента и принимают значения в $\mathcal{A}$,

R_t обозначают **вознаграждение** и принимают значения в $\mathcal{R}$.

Случайность может возникать как в силу вероятностного характера переходов между состояниями, так и в силу вероятностного характера выбора возможных действий.

Конкретную реализацию этого процесса называют **траекторией** взаимодействия агента со средой.

Для траектории будем использовать запись $\tau = (s_0, a_0, r_1, s_1, a_1, \dots)$, понимая под символами s_t, a_t, r_t конкретные состояния, действия, вознаграждения, возникшие в текущем взаимодействии агента со средой.

Взаимодействие агента со средой

Взаимодействие агента со средой может быть:

1. не ограниченным по времени (англ. infinite horizon): $S_0, A_0, R_1, S_1, A_1, \dots$
2. конечным по длительности (англ. finite horizon): $S_0, A_0, R_1, S_1, A_1, \dots, R_{T-1}, S_{T-1}, A_{T-1}, R_T, S_T$,
где T обозначает момент окончания взаимодействия.

В последнем случае:

либо мы искусственно ограничиваем сверху время взаимодействия агента со средой,
либо же среда имеет **терминальные** состояния, в которых взаимодействие агента со средой прекращается.

Конечный временной период, в течении которого агент действует в среде до завершения взаимодействия, называется **эпизодом**, а сам процесс, описывающий взаимодействие агента со средой называют **эпизодическим**.

При изложении теории удобно считать, что взаимодействие не ограничено во времени.

Для этого можно полагать, что из терминального состояния все действия ведут в него же с нулевым вознаграждением.

Пример



Проиллюстрируем описанные выше понятия на примере игры в шахматы.

Состояние среды S_t — это текущее положение фигур на доске.

Действие агента A_t — это ход той или иной фигурой.

Новое состояние S_{t+1} — это положение после хода противника.

S — множество всевозможных положений фигур на доске,

$\mathcal{A}$ — множество всевозможных ходов, причём

для конкретного состояния S_t есть свой набор допустимых ходов $\mathcal{A}(S_t)$.

Взаимодействие агента со средой эпизодическое.

Вознаграждения можно формировать различными способами.

1. Простейший способ заключается в том, чтобы дать большое вознаграждение за победу и штраф за проигрыш. Однако, обычно при начальном взаимодействии со средой агент совершает действия случайным образом, поскольку у него нет каких либо априорных знаний о среде. Добиться положительного вознаграждения, то есть победы, при случайных ходах практически невозможно. А значит обучение будет чрезвычайно долгим.

2. Более разумным подходом к формированию системы вознаграждений будет следующий:

за ход, ведущий к взятию фигуры противника, можно давать положительное вознаграждение,

за ход, ведущий к потере своей фигуры, — отрицательное вознаграждение.

Причём в зависимости от значимости фигуры можно варьировать модуль вознаграждения. Также можно ввести вознаграждения за шах и мат.

Основные концепции RL: стратегия

Рассмотрим подробно основные концепции обучения с подкреплением, относящиеся к агенту:

- 1) стратегия,
- 2) вознаграждения и доход,
- 3) функция ценности состояний,
- 4) модель среды.

Стратегия (англ. policy) — набор правил, определяющих поведение агента в любом состоянии.

Детерминированная стратегия — это отображение π из множества состояний S в множество действий $\mathcal{A}$, то есть $\pi : S \rightarrow \mathcal{A}$.

Стохастическая стратегия — это отображение из множества состояний S в набор вероятностей выбора действий из множества $\mathcal{A}$. В этом случае будем использовать обозначение $\pi(a|s)$ для вероятности выбора действия $a \in \mathcal{A}$ в состоянии $s \in S$, причём

$$\pi(a|s) \in [0, 1] \text{ и } \sum_{a \in \mathcal{A}} \pi(a|s) = 1.$$

Основные концепции RL: вознаграждение и доход

Вознаграждение — это то число, которое получает агент после совершения действия в среде.

Детерминированное вознаграждение — это функция $r: S \times \mathcal{A} \rightarrow \mathbb{R}$.

То есть $R_{t+1} = r(S_t, A_t)$ — это вознаграждение за выход из состояния S_t при совершении действия A_t .

Стохастическое вознаграждение — это случайная величина, распределение которой зависит от текущего состояния среды S_t и от выбранного действия A_t .

Доход, полученный после совершения действия в момент времени t , обозначается G_t .

Доход равен суммарному вознаграждению с момента времени t :

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots,$$

где $\gamma \in [0, 1]$ **коэффициент обесценивания** (англ. discount factor). Коэффициент γ отражает баланс между влиянием на общий доход ближайшего вознаграждения и будущих вознаграждений за совершённые действия.

Если $\gamma = 0$, то $G_t = R_{t+1}$ и максимизация дохода — это максимизация ближайшего вознаграждения.

Если $\gamma = 1$, то будущие вознаграждения одинаково важны для общего дохода.

При эпизодическом взаимодействии выбор $\gamma < 1$ стимулирует агента быстрее завершить эпизод.

Например, если успешное завершение эпизода даёт большое вознаграждение, то

завершение эпизода через 10 ходов прибавит к доходу вознаграждение с коэффициентом γ^{10} ,

а завершение через 1000 ходов — с коэффициентом γ^{1000} .

Основные концепции RL: стратегия, максимизирующая доход

Доход агента с начала взаимодействия равен $G_0 = R_1 + \gamma R_2 + \gamma^2 R_3 + \dots = \sum_{t=0}^{\infty} \gamma^t R_{t+1}$.

Цель агента — это максимизация дохода при взаимодействии со средой. Формализуем эту цель.

Агент действует по некоторой стратегии π . Тогда величина

$$J(\pi) = \mathbb{E}_{\pi}[G_0].$$

означает ожидаемый доход агента, действующего по стратегии π , со старта взаимодействия.

Если сгенерировать множество траекторий взаимодействия агента, действующего стратегии π , со средой и по каждой траектории найти полученный доход, то усреднение этих доходов является приближением величины $J(\pi)$.

Цель агента — это поиск **оптимальной** стратегии π_* , **максимизирующей** величину $J(\pi)$, то есть

$$\pi_* = \operatorname{argmax}_{\pi} J(\pi).$$

Основные концепции RL: функция ценности

Функция ценности состояния (англ. state value function) или V -функция — это функция $v_\pi : \mathcal{S} \rightarrow \mathbb{R}$, выражающая насколько хорошо для агента нахождение в данном состоянии с точки зрения длительной перспективы при заданной стратегии поведения π .

Формально, ценность состояния s определяется как математическое ожидание дохода G_t при старте из состояния $S_t = s$ и следовании стратегии π :

$$v_\pi(s) = \mathbb{E}_\pi[G_t | S_t = s] = \mathbb{E}_\pi[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots | S_t = s].$$

Аналогичным образом определяется **функция ценности состояния-действия** или Q -функция. Это функция $q_\pi : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$, значения которой определяются в виде математического ожидания дохода G_t при старте из состояния $S_t = s$, осуществления действия $A_t = a$ и затем следовании стратегии π :

$$q_\pi(s, a) = \mathbb{E}_\pi[G_t | S_t = s, A_t = a] = \mathbb{E}_\pi[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots | S_t = s, A_t = a].$$

Ряд методов поиска оптимальной стратегии основан именно на функциях ценности. Далее будет ясно, что оптимальная стратегия — это выбор тех действий, которые приводят в состояния с наибольшей ценностью.

Основные концепции RL: модель среды

Модель среды — это набор правил, описывающий механизм смены состояний среды в ответ на действия агента.

В реальных задачах модель среды агенту не доступна.

Вообще говоря, каждое новое состояние среды может зависеть от всех прошлых состояний и действий агента.

Пусть $h = (S_0, A_0, \dots, A_{t-1}, S_t)$ — это история взаимодействия агента со средой до момента времени t .

Вероятность перехода в новое состояние $S_{t+1} = s'$ при совершении действия $A_t = a$ обозначим за

$$\mathbb{P}(S_{t+1} = s' | H_t = h, A_t = a).$$

Работа с такой моделью сложна, при формировании стратегии агенту надо учитывать все прошлые шаги.

На практике полагают, что среда **марковская**, то есть

вероятность нового состояния среды $S_{t+1} = s'$ при текущем состоянии среды $S_t = s$ и действии агента $A_t = a$ **не зависит от предыдущих состояний и действий:**

$$\mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a) = \mathbb{P}(S_{t+1} = s' | H_t = h, A_t = a).$$

В марковском случае задать модель среды — это значит задать вероятности

$$\mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a), \text{ для всех возможных } s', s \in \mathcal{S}, a \in \mathcal{A}.$$


Основные концепции RL: модель среды

В случае **полностью наблюдаемой** марковской среды обученный агент способен по текущему наблюдению о состоянии среды принять оптимальное решение о действии.

Если марковская среда **частично наблюдаема**, то наблюдения O_t в момент времени t может быть недостаточно для принятия правильного решения, так как цепочка наблюдений может и **не быть марковской**.

В этом случае агенту необходимо использовать историю прошлых наблюдений и действий для построения внутреннего состояния, чтобы быть способным принять правильное решение.

То есть агенту надо построить марковскую цепочку внутренних состояний.



Например, в лабиринте выше наблюдения агента ограничены 8-ю ближайшими клетками, что не позволяет ему установить своё местоположение.

Однако, это возможно, если хранить историю некоторого количества последних шагов.

Основные концепции RL: классификация моделей среды

1. Среды с полной информацией и среды с неполной информацией (или частично наблюдаемые среды).
2. Среды с **дискретным** изменением времени и среды с **непрерывно** меняющимся временем.
Далее, будем обсуждать только дискретный случай.
3. Среды с **дискретным** набором состояний и среды с **непрерывно** меняющимися состояниями.
4. Среды с **дискретным** набором действий и среды с **непрерывно** меняющимися действиями.
5. **Детерминированные** среды и **стохастические** среды.

Для детерминированного случая распределение $P(S_{t+1} = s' | S_t = s, A_t = a)$ вырождено для любой пары (s, a) , то есть новое состояние однозначно определяется по паре (s, a) .

6. **Стационарные** среды или **нестационарные** среды.

Если вероятности перехода из пары (s, a) в новое состояние s' не меняются со временем, то среда стационарна.

7. **Эпизодические** среды и среды с **неограниченным по длительности** взаимодействием.

В эпизодических средах есть набор терминальных состояний, в которых взаимодействие агента со средой прекращается.

Основные концепции RL: методы обучения

Если **модель среды есть**, то агент может заранее **спланировать оптимальную стратегию** действий.

Надо решить некоторую задачу оптимизации.

При этом агенту не нужно даже взаимодействовать со средой.

Если же **модели среды нет**, то агент **обучается в ходе взаимодействия со средой**.

Базовый подход — это метод проб и ошибок с анализом полученного опыта, в ходе которого формируется лучшая стратегия.

Общая схема обучения во взаимодействии со средой:

Шаг 0. Агент фиксирует стратегию, которая, например, случайным образом выбирает действия.

Шаг 1. Агента взаимодействует со средой по выбранной стратегии и накапливает опыт.

Шаг 2. Агент немного меняет стратегию в сторону более частого выбора тех действий, которые приносят больший доход. Затем снова к Шагу 1.

Методы обучения можно разделить на несколько типов.

1. Методы **на основе функций ценности** (англ. value-based methods).

Суть в построении оценок этих функций и формировании стратегии на их основе.

2. Методы **на основе стратегии** (англ. policy-based methods).

Суть в непосредственном формировании стратегии.

3. Методы **на основе модели** (англ. model-based methods).

Суть в построении приближения модели среды и её использовании для выбора каждого нового действия.

Основные концепции RL: модель среды

Основные методы решения задач RL **на основе функций ценности**:

1. методы **динамического программирования** (применяются при знании полной модели среды),
2. методы проб и ошибок, **методы Монте-Карло** (могут применяться, когда модели среды нет, а задача разбивается на эпизоды, тогда агент может обучаться после каждого эпизода),
3. методы на основе временных различий или **TD-методы** (англ. Time Difference, могут также применяться, когда модели среды нет, обучение может происходить после каждого действия).

Методы **на основе стратегии** основаны на непосредственной максимизации целевой функции $J(\pi)$.

1. методы black-box оптимизации,
2. методы поиска стратегии по семейству параметризованных стратегий.

Наиболее успешные методы являются **комбинацией** различных типов методов.

Общая структура курса

Табличные методы

Методы ДП

- Итерация по стратегии
- Итерация по ценности

Методы на основе функций ценности

- Методы Монте-Карло
- SARSA
- Q-обучение
- n-step SARSA
- TD(λ)

DeepRL

Методы на основе функций ценности

- DQN
- DoubleDQN + PER

Методы на основе стратегии

- REINFORCE
- REINFORCE с базой
- CEM


Комбинированные методы

- Актор-Критик, A2C
- TRPO, PPO
- DDPG, TD3
- SAC

Для запуска кода можно использовать пакет Anaconda3 версии 2025.12-2 (версия Python 3.13.9).

https://repo.anaconda.com/archive/Anaconda3-2025.12-2-Windows-x86_64.exe

Книги



Обучение с подкреплением | Саттон Ричард С., Барто Эндрю Г.