

Введение в обучение с подкреплением

Тема 2: Многорукие бандиты

Лектор: Кривошеин А.В.

Вопросы

Q1. В чём заключается задача, решаемая методами RL?

Q2. Что такое доход и в чём цель агента?

Q3. В чем основные отличия обучения на основе методов RL от методов обучения с учителем?

Напоминание


Суть RL:

научить обучаемого агента предпринимать "хорошие" последовательности действий в ходе взаимодействия со средой для эффективного достижения цели.

Цель агента: поиск стратегии поведения, дающей максимальный доход.

Схема взаимодействия:

обучаемый агент действует в окружающей его среде, среда реагирует на действия агента.



Обозначения:

S — множество состояний, S_t состояние в момент времени t ,
 $\mathcal{A}$ — множество действий, A_t действие в момент времени t ,
 $\mathcal{R}$ — множество вознаграждений, R_t вознаграждение в момент времени t .

Взаимодействие агента со средой — это **дискретный случайный процесс**: $S_0, A_0, R_1, S_1, A_1, \dots$

Конкретная реализация этого процесса — это **траектория** взаимодействия агента со средой.

Многорукий бандит: базовая идея

Многорукий бандит (англ. Multi-Armed Bandit) в RL — это простая, но широко применяемая модель принятия последовательности решений в условиях неопределённости.

Перед нами два игровых автомата.

За выбор автомата можно с некоторой вероятностью получать либо +1 руб., либо 0 руб.



Многорукий бандит: базовая идея

Рассмотрим ситуацию с несколькими сделанными выборами:

	0		
	+1		

Многорукий бандит: базовая идея

Рассмотрим ситуацию с несколькими сделанными выборами:

	0		
	+1	0	0

Основной вопрос: Как действовать, чтобы в **длительной перспективе** получить **наибольший** выигрыш?

Многорукий бандит: общая постановка

Пусть агенту в каждый момент времени t надо выбрать одно действие из k возможных.

Можно представлять, что агент находится перед некоторым устройством с k рычагами (k -рукий бандит).

В каждый дискретный момент времени надо выбрать один из рычагов и получить вознаграждение или штраф.



С точки зрения общих понятий RL:

1. Агент всегда находится **в одном состоянии** среды.
2. Выбор одного из рычагов — это **действие**, перенумеруем их от 1 до k , то есть $\mathcal{A} = \{1, \dots, k\}$.
3. **Вознаграждение** за действие — это реализация случайной величины с некоторым распределением вероятностей.
Для каждого действия эта случайная величина своя.

Стратегия — это принцип выбора того или иного рычага в каждый дискретный момент времени.

Задача агента: поиск стратегии, максимизирующей доход. То есть надо найти самый выгодный рычаг.

Многорукий бандит: приложения

Методы решения задачи о многоруком бандите используются
в работе **рекомендательных систем** и в системах поисковой выдачи.

Например, сайт интернет-магазина — это k -рукий бандит.


Карточки с товарами — это рычаги.

Выбор рычага — это помещение товара в блоке рекомендаций для пользователя.

Вознаграждения зависят от действий пользователя, купил он товар или нет.

Задача: найти лучший набор карточек для выдачи в блоке рекомендаций по запросу пользователя?

Out[]:=



Многорукий бандит: приложения

Классический подход к решению задачи: метод АВ-тестирования или стратегия **Explore Then Commit**.

Суть стратегии: выбрать каждое действие фиксированное число раз, затем определить лучшее.

На практике формируются гипотезы об успешности тех или иных карточек с товарами.


Выделяется период времени для тестирования гипотез: карточки равновероятно показываются пользователям.

После тестирования делается статистический вывод о наиболее успешных карточках.

Схема не является гибкой и ведёт к «заморозке» выдачи:

успешные товары будут появляться всегда, менее успешные — никогда.

Out[-]/DisplayForm=



Стратегии многоруких бандитов начинают работать с нуля, без тестирования, нет проблемы «заморозки» выдачи.

Более того, предпочтения пользователей могут меняться со временем и методы многоруких бандитов могут это учитывать в своей работе.

Многорукий бандит: обозначения

1) За A_t обозначим случайную величину, которая определяет **действие** в момент времени t (то есть индекс выбираемого рычага).

2) За R_t обозначим случайную величину, которая определяет **вознаграждение** в момент времени t . Эта случайная величина зависит от сделанного действия в момент времени t .

Взаимодействие агента с многоруким бандитом можно записать в виде дискретного процесса

$$A_1, R_1, A_2, R_2, \dots, A_t, R_t, \dots$$

Истинная ценность действия $a \in \mathcal{A}$ — это математическое ожидание случайной величины, соответствующей вознаграждению за действие a :

$$q_*(a) := \mathbb{E}[R_t | A_t = a].$$

Левая часть от t не зависит, то есть мы предполагаем, что распределения **стационарны** (не меняются со временем).

Знание лучшего действия $a^* = \operatorname{argmax}_a q_*(a)$ решало бы задачу агента.

Но истинные ценности агенту **неизвестны**.

На чём же агенту строить свою стратегию?

Многорукий бандит: оценки ценностей

У агента к моменту времени t есть набор полученных вознаграждений за выбор тех или иных действий.

Работа многих стратегий основана на формировании **оценок** истинных ценностей $q_*(a)$.

Оценку ценности действия a к моменту времени t обозначим за $Q_t(a)$.

Это усреднение фактически полученных вознаграждений за выбор рычага a :

$$Q_t(a) =$$

$$(\text{сумма вознаграждений за выбор рычага } a \text{ к моменту времени } t) / (\text{число выборов рычага } a \text{ к моменту времени } t) = \frac{\sum_{i=1}^t R_i [A_i = a]}{\sum_{i=1}^t [A_i = a]}.$$

Обозначение через квадратные скобки — это скобки Айверсона, для предиката $\mathcal{P}(x)$ верно, что

$$[\mathcal{P}(x)] = \begin{cases} 1, & \mathcal{P}(x) = \text{True}, \\ 0, & \mathcal{P}(x) = \text{False}. \end{cases}$$

Закон больших чисел гарантирует, что оценка $Q_t(a)$ сойдётся к истинной ценности $q_*(a)$, если число выборов действия a стремится к бесконечности.

Формально, чтобы найти $Q_t(a)$, надо хранить все прошлые вознаграждения.

Многорукий бандит: обновление оценок

Зафиксируем действие a . Пусть r_n это вознаграждение, полученное после n -го выбора этого действия.

Оценка ценности действия a после выбора этого действия n раз имеет вид:

$$Q_{n+1} = \frac{r_1 + r_2 + \dots + r_{n-1} + r_n}{n}, \quad n \geq 1.$$

Q_1 — это начальная оценка (либо ноль, либо случайно, либо из каких-то иных соображений).

Можно обновлять оценку **инкрементно**:

$$Q_{n+1} = \frac{n-1}{n} Q_n + \frac{1}{n} r_n = Q_n + \frac{1}{n} (r_n - Q_n).$$

Сформулируем полученное правило обновления более абстрактно:

НоваяОценка = СтараяОценка + Шаг (ЦельОбновления – СтараяОценка).

Это правило обновления будет далее встречаться довольно часто.

Разницу (**ЦельОбновления – СтараяОценка**) называют **ошибкой оценки**.

Если обновить оценку в направлении цели обновления, то новая ошибка оценки станет меньше.

В нашем случае цель обновления равна текущему вознаграждению r_n , которое можно трактовать как искажённое шумом истинное вознаграждение за действие: $r_n = q_*(a) + \text{noise}$.

Заметим, что в инкрементной реализации вычисления оценки **величина шага обновления меняется с каждой новой оценкой**.

Многорукий бандит: величина шага

Рассмотрим модификацию формулы обновления оценок ценности действия в виде:

$$Q_{n+1} = Q_n + \alpha_n(r_n - Q_n) = (1 - \alpha_n) Q_n + \alpha_n r_n.$$

Когда параметр α_n близок к 1, то больший вклад в формирование новой оценки дают только что полученные вознаграждения.

Когда параметр α_n близок к 0, то больший вклад в формирование новой оценки даёт имеющаяся оценка.

Условия, при которых гарантируется сходимость оценок Q_n к истинным ценностям действий,

называют **условиями Роббинса-Монро**:

$$\sum_n \alpha_n = \infty, \quad \sum_n \alpha_n^2 < \infty, \quad \text{например, можно выбрать } \alpha_n = \frac{1}{n}.$$


В стационарном случае, когда истинные ценности действий $q_*(a)$ не изменяются со временем, последовательность $\{\alpha_n\}$ имеет смысл выбирать именно так.

Многорукий бандит: величина шага

В нестационарном случае истинные ценности действий $q_*(a)$ могут меняться со временем. Это значит, что при обновлении оценок имеет смысл давать больший вес последним полученным вознаграждениям. В этом случае можно выбрать постоянный шаг обучения $\alpha_n = \alpha$, где α некоторая константа от 0 до 1. Причём,

$$Q_{n+1} = (1 - \alpha) Q_n + \alpha r_n = (1 - \alpha)[(1 - \alpha) Q_{n-1} + \alpha r_{n-1}] + \alpha r_n = \dots = Q_{n+1} = (1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha (1 - \alpha)^{n-i} r_i,$$

то есть оценка Q_n является **экспоненциально взвешенным средним** прошлых вознаграждений $r_1, \dots, r_n$ и начальной оценки Q_1 .



Многорукий бандит: базовые стратегии

Пусть к моменту времени t сформированы некоторые оценки ценностей действий $Q_t(a)$, $a \in \mathcal{A}$.

Сформулируем две базовые стратегии поведения:

1. **Жадный выбор** — это выбор действия с максимальной текущей оценкой $Q_t(a)$, то есть $A_t = \arg \max_{a \in \mathcal{A}} Q_t(a)$.

Про такой выбор ещё говорят, что это **шаг использования** имеющегося знания (англ. exploiting step).

2. **Нежадный выбор** — это выбор случайного действия некоторым образом.

Про такой выбор ещё говорят, что это **шаг исследования** (англ. exploring step).

Жадный выбор максимизирует вознаграждение на одном шаге. Однако, может оказаться, что лучшее в перспективе действие не будет выбираться.

Нежадный выбор может дать большую награду в перспективе (поскольку может улучшить оценки действий), хотя может дать меньшее вознаграждение в данный момент времени по сравнению с жадным выбором.

Нахождение баланса между использованием знаний о среде и исследованием среды при взаимодействии агента со средой является одной из основных задач в обучении с подкреплением (англ. **exploration vs exploitation trade-off**). Любые методы он-лайн обучения в итоге условно сводятся к вопросам:

«какое действие сейчас лучше?» и «стоит ли опробовать новое действие?»

Оптимальный баланс между этими стратегиями зависит от точности оценок и числа шагов, оставшихся до конца.

Многорукий бандит: базовые стратегии

При жадном выборе всегда будет выбираться нижний автомат.

Хотя он может оказаться и не оптимальным выбором.

	0			$q_*(B) = 0.8$
---	---	--	--	----------------

$Out[-] =$

	+1	0	0	$q_*(H) = 0.4$
---	----	---	---	----------------

Как всё же проводить исследование, но получать как можно больший выигрыш?

Многорукий бандит: ϵ -жадная стратегия

Рассмотрим различные способы формирования нежадного выбора.

Простейший способ заключается в **выборе** каждого действия с **равной вероятностью**. Ясно, что такой подход не способствует увеличению получаемых вознаграждений с течением времени.

Стратегия, которая совмещает жадный и равновероятный выбор — это **ϵ -жадная стратегия**:

- с вероятностью ϵ выбирается любое действие (например, равновероятно),
- с вероятностью $1 - \epsilon$ выбирается жадное действие.

При такой стратегии на бесконечном промежутке времени каждое действие будет выбрано бесконечное число раз. Тогда все оценки действий $Q_t(a)$ сойдутся к истинным значениям $q_*(a)$. При жадной стратегии такой гарантии нет.

Многорукий бандит: псевдокод

Приведём алгоритм обучения агента по ε -жадной стратегии с формированием оценок ценностей по методу выборочного среднего.

Инициализировать для i от 1 до k :

$Q(i) \leftarrow 0$ (оценка i -го действия)

$N(i) \leftarrow 0$ (число выборов i -го действия)

Повторять:

$a \leftarrow \begin{cases} \arg \max_i Q(i) & \text{с вероятностью } 1 - \varepsilon \\ \text{случайный выбор из } \{1, \dots, k\} & \text{с вероятностью } \varepsilon \end{cases}$

$r \leftarrow \text{bandit}(a)$

$N(a) \leftarrow N(a) + 1$

$Q(a) \leftarrow Q(a) + \frac{1}{N(a)} (r - Q(a))$

Неоднозначности выбора максимума разрешаются случайным образом.

Функция $\text{bandit}(a)$ в псевдокоде означает, что надо выполнить действие a и вернуть вознаграждение, соответствующее сделанному действию.

Многорукий бандит: оптимистичные старты

Отметим, что оценки ценностей действий зависят от начальных оценок $Q_1(a)$.

Если оценки формируются по методу выборочного среднего, то эта зависимость сразу пропадает, так как $\alpha_1 = 1$ и

$$Q_2 = (1 - \alpha_1) Q_1 + \alpha_1 r_1 = r_1.$$

Если оценки формируются с постоянным шагом обучения, то эта зависимость убывает к нулю, так как $\alpha \in (0, 1)$ и

$$Q_{n+1} = (1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha (1 - \alpha)^{n-i} r_i.$$

Работа некоторых стратегий на основе обновления оценок ценностей действий также может зависеть от начальных оценок $Q_1(a)$. На практике это можно использовать, чтобы включить априорную информацию о вознаграждениях. Эта модификация называется **оптимистичным стартом**.

Например, выставив начальные оценки выше уровня истинных оценок, мы поощрим агента к исследованию в начале процесса, даже если он действует по жадной стратегии. Например, если $q_*(a) < 3$ для всех a , то в качестве начальных оценок можно положить $Q_1(a) = 5$. Каждое действие будет опробовано несколько раз, пока уровень оценок не приблизится к истинным значениям.

Для нестационарной задачи это дополнительное поощрение к исследованию будет носить временный характер. Старт происходит только один раз, а истинные ценности всё время меняются.

Многорукий бандит: SoftMax-исследование

При ε -жадной стратегии действие выбирается

- либо жадно,
- либо равновероятно.

Но можно выбирать действия пропорционально текущим оценкам $Q_t(a)$.

Вектор оценок $Q_t(a)$ можно перевести в набор вероятностей с помощью функции $\text{SoftMax} : \mathbb{R}^k \rightarrow [0, 1]^k$

$$\text{SoftMax}(x) = \frac{1}{e^{x_1} + \dots + e^{x_k}} (e^{x_1}, \dots, e^{x_k}), \text{ где } x = (x_1, \dots, x_k).$$

SoftMax-исследование: новое действие выбирается на основе распределения вероятностей


$$P_t(a) = \frac{\exp\left(\frac{Q_t(a)}{\tau}\right)}{\sum_{a \in \mathcal{A}} \exp\left(\frac{Q_t(a)}{\tau}\right)}, \quad a \in \mathcal{A}.$$

Параметр τ называют **температурным коэффициентом**.

- Большие значения τ ведут к тому, что все действия будут выбираться с почти равной вероятностью.
- Малые значения τ ведут к тому, что чаще будут выбираться действия с большей текущей оценкой ценности $Q_t(a)$.

Многорукий бандит: SoftMax-исследование

Иллюстрация роли параметра τ на вид распределения вероятностей.



Как определять какая стратегия более эффективна?

Многорукий бандит: как сравнивать стратегии?

Эмпирически: запуск симуляций взаимодействия и сравнение кривых изменения среднего дохода.

Теоретически: на основе понятия **цены обучения** или **сожаления** (англ. regret).

Оптимальная стратегия заключается в выборе действия с наибольшей истинной ценностью $q_*(a)$.

Любая другая стратегия обучения

совершает не оптимальные выборы действия и каждый выбор удаляет нас от теоретически максимального ожидаемого дохода.

Цена обучения на шаге t — это разница между максимальной истинной ценностью и истинной ценностью сделанного действия.

Пусть $q^{\text{opt}} = \max_{a \in \mathcal{A}} q_*(a)$ обозначает максимальное значение ценности.

$$\Delta_a = q^{\text{opt}} - q_*(a) = q^{\text{opt}} - \mathbb{E}[R_t | A_t = a_t].$$

Ясно, что $\Delta_a \geq 0$ для всех $a \in \mathcal{A}$.

Многорукий бандит: как сравнивать стратегии?

После T шагов взаимодействия, совершив действий $a_1, \dots, a_T$, можно определить

полную цену обучения за T шагов (англ. total regret) — это сумма сожалений за каждое действие

$$L_T = \sum_{t=1}^T (q^{\text{opt}} - q_*(a_t)) = \sum_{t=1}^T \Delta_{a_t} = \sum_{a \in \mathcal{A}} N_T(a) \Delta_a,$$

где $N_T(a)$ — это число выборов действия a к моменту времени T .

В силу стохастичности стратегий более правильно говорить об усреднённой полной цене обучения

$$\mathbb{E}[L_T] = T q^{\text{opt}} - \sum_{t=1}^T \mathbb{E}[q_*(A_t)] = \sum_{a \in \mathcal{A}} \mathbb{E}[N_T(a)] \Delta_a.$$

Задача **минимизация** полной цены обучения равносильна максимизации получаемого дохода.

Чем **медленнее растёт** $\mathbb{E}[L_T]$ с ростом T , тем **эффективнее** выбранная стратегия.

Хорошая стратегия должна обеспечивать:

малое число выборов действия a с высокой ценой обучения Δ_a ,

как можно более частый выбор действий с очень малой или нулевой ценой обучения.

Многорукий бандит: сравнение стратегий

Жадная стратегия: при удачном исходе цена обучения ограничена и не растёт.

Но если жадное действие не оказалось оптимальным, то цена обучения растёт линейно относительно T , то есть

$$\mathbb{E}[L_T] = O(T) \text{ при } T \rightarrow +\infty.$$

ε -Жадная стратегия: в течении T шагов в среднем на $[\varepsilon T]$ шагах действие выбирается случайно.

Значит в среднем на $\varepsilon T \frac{k-1}{k}$ шагах выбор будет не оптимальным.

Обозначим за Δ разницу между максимальной истинной ценностью и вторым по истинной ценности действием.

Тогда верна оценка

$$\mathbb{E}[L_T] \geq \varepsilon T \frac{k-1}{k} \Delta, \text{ а значит } \mathbb{E}[L_T] = O(T) \text{ при } T \rightarrow +\infty.$$

То есть цена обучения также растёт линейно относительно T ,

хотя эта стратегия гарантировано может найти оптимальное действие.

SoftMax-исследование с параметром τ : известно, что цена обучения также растёт линейно относительно T .

Многорукий бандит: теоретические границы роста

Известен результат, который устанавливает нижнюю границу роста ожидаемой полной цены обучения.

Теорема (Lai—Robbins, 1985).

Асимптотически ожидаемая полная цена обучения растёт по крайней мере логарифмически относительно T :

$$\mathbb{E}[L_T] \geq \ln T \sum_{a: \Delta_a > 0} \frac{\Delta_a}{D_{\text{KL}}(p(r|a) \| p(r|a_*))} + o(\ln T) \quad \text{при } T \rightarrow +\infty,$$

где $p(r|a)$ — это вероятностное распределение вознаграждений за выбор рычага a , а a_* — это оптимальный рычаг.

В знаменателе формулы находится величина **KL-дивергенции** (дивергенции Кульбака-Лейблера) между распределениями вознаграждений за оптимальное и иное действие.

Для двух дискретных вероятностных распределений $p = (p_1, \dots, p_k)$ и $q = (q_1, \dots, q_k)$ KL-дивергенция определяется по формуле

$$D_{\text{KL}}(p \| q) = \sum_{i=1}^k p_i \log_2 \frac{p_i}{q_i}.$$

Многорукий бандит: теоретические границы роста

KL-дивергенция обладает свойством, что $D_{\text{KL}}(p \parallel q) \geq 0$,

причём $D_{\text{KL}}(p \parallel q) = 0$ в том и только том случае, когда $p = q$.

Поэтому KL-дивергенцию используют для измерения «**расстояния**» **между распределениями**, хотя формально это не метрика (нет симметричности и неравенства треугольника).

Установленная нижняя граница

$$\mathbb{E}[L_T] \geq \ln T \sum_{a: \Delta_a > 0} \frac{\Delta_a}{D_{\text{KL}}(p(r|a) \parallel p(r|a_*))} + o(\ln T) \quad \text{при } T \rightarrow +\infty$$

означает, что любое обучение требует затрат на исследование и эти затраты принципиально **не могут быть меньше логарифмических**.

Суть константы около $\ln T$ в том, что чем больше распределение вознаграждений за действие a «похоже» на распределение вознаграждений за оптимальное действие, тем больше должна быть выборка, чтобы отличить эти два распределения друг от друга.

Вопрос: существуют ли алгоритмы, позволяющие достичь такого роста цены обучения?