

Введение в обучение с подкреплением

Тема 2: Многорукие бандиты (продолжение)

Лектор: Кривошеин А.В.

Вопросы

Q1. В чём заключается задача о многоруких бандитах?

Q2. Каковы основные стратегии выбора действий?

Q3. Приведите инкрементную формулу оценки выборочного среднего?

Многорукий бандит: теоретические границы роста

Цена обучения на шаге t : $\Delta_a = q^{\text{opt}} - q_*(a)$

Ожидаемая полная цена обучения за T шагов:

$$\mathbb{E}[L_T] = \mathbb{E}\left[\sum_{t=1}^T (q^{\text{opt}} - q_*(a_t))\right] = \sum_{a \in \mathcal{A}} \mathbb{E}[N_T(a)] \Delta_a.$$

Нижняя граница

$$\mathbb{E}[L_T] \geq \ln T \sum_{a: \Delta_a > 0} \frac{\Delta_a}{D_{\text{KL}}(p(r|a) \| p(r|a_*))} + o(\ln T) \quad \text{при } T \rightarrow +\infty$$

Затраты на исследование принципиально **не могут быть меньше логарифмических**.

Вопрос: существуют ли алгоритмы, позволяющие достичь такого роста цены обучения?

Многорукий бандит: ВДГ-стратегия


Стратегия, основанная на **ВДГ-действиях**

(ВДГ сокращение от “Верхняя Доверительная Граница”, англ. Upper Confident Bound, UCB), позволяет выбирать нежадные действия по их потенциалу оказаться оптимальными.

Идея: выбрав один рычаг a несколько раз, получается выборка из вознаграждений.

Мы использовали только среднее значение выборки.

Но можно найти доверительный интервал, в котором с некоторой степенью уверенности лежит истинное значение ценности $q_*(a)$.



У **действия 2** выше значение среднего вознаграждения и меньше интервал, где истинное среднее вероятнее всего находится.

У **действия 1** значение среднего вознаграждения меньше, но наша уверенность в оценке гораздо ниже, и истинное среднее может быть больше имеющейся оценки.

Поэтому для уточнения оценки и потенциально получения большего дохода имеет смысл далее выбрать действие 1.

Многорукий бандит: ВДГ-стратегия

Общий принцип формирования стратегии:

выбор действия с максимальной оценкой ценности с учётом недостоверности оценок.

Этот принцип ещё известен как **оптимизм в условиях неопределённости** (англ. optimism under uncertainty):

— если мы уверены в оценке ценности действия, то для него уже можно не проводить шаги исследования, а просто выбирать или не выбирать это действие в зависимости от величины этой оценки;

— если мы не уверены в оценке ценности действия, то его надо почаще выбирать, чтобы увеличить нашу уверенность в оценке, даже если само значение оценки не самое большое.

Сформулированный принцип выражается в следующей формуле

$$A_t = \operatorname{argmax}_{a \in \mathcal{A}} (Q_t(a) + U_t(a)),$$

где $U_t(a)$ — это бонус для исследования, который формируется так, чтобы истинная ценность действия $q_*(a)$ с высокой вероятностью удовлетворяла бы неравенству

$$q_*(a) \leq Q_t(a) + U_t(a).$$

Многорукий бандит: ВДГ-стратегия

Семейство ВДГ-стратегий — это набор различных способов формирования добавки $U_t(a)$.

Один из способов, известный как UCSB1, заключается в использовании формулы

$$A_t = \arg \max_a \left(Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right),$$

где c число, отражающее степень доверия (подбирается эмпирически, $c \approx 1$),

$N_t(a)$ число выборов действия a к моменту времени t .

Второе слагаемое называют **мерой недоверности**.

При каждом выборе действия a недоверность оценки $Q_t(a)$ снижается,
однако, с течением времени недоверность всех действий увеличивается.


Таким образом, потенциально будут выбираться все действия, но те у которых малы оценки будут выбираться с уменьшающейся частотой.

Стратегия на основе ВДГ-действий хорошо показывает себя на многоруком бандите, но её сложно обобщить на иные задачи.

Многорукий бандит: ВДГ-стратегия

Известно, что **ВДГ-стратегия** обеспечивает **логарифмический рост** усреднённой полной цены обучения (Auer et al., 2002).

Иллюстрация работы ВДГ-стратегии.



Известно, что ВДГ-стратегия обеспечивает логарифмический рост цены обучения

Многорукий бандит: ВДГ-стратегия, вывод

Теорема (неравенство Хёфдинга). Пусть $\xi_1, \dots, \xi_M$ — это независимые в совокупности случайные величины, одинаково распределённые со случайной величиной ξ , h некоторая ограниченная функция, действующая из значений ξ в $[c, d]$.

Тогда для каждого $\varepsilon > 0$ верно неравенство

$$\mathbb{P}\left[\left|\frac{1}{M} \sum_{i=1}^M \xi_i - \mathbb{E}[\xi]\right| > \varepsilon\right] \leq 2 \exp\left(-\frac{2 \varepsilon^2 M}{\Delta^2}\right),$$

где вероятность берётся по случайным величинам $\xi_1, \dots, \xi_M \sim P^M$,

P — это распределение вероятностей для ξ ,

$\Delta = d - c$.

Неравенство можно инвертировать:

$$\mathbb{P}\left[\left|\frac{1}{M} \sum_{i=1}^M \xi_i - \mathbb{E}[\xi]\right| \leq \varepsilon\right] \geq 1 - \delta,$$

$$\text{где } \delta = 2 \exp\left(-\frac{2 \varepsilon^2 M}{\Delta^2}\right), \text{ и верно } \varepsilon = \Delta \sqrt{\frac{1}{2M} \ln \frac{2}{\delta}}.$$

Многорукий бандит: ВДГ-стратегия, вывод

Неравенство Хёфдинга : $\mathbb{P}\left[\left|\frac{1}{M} \sum_{i=1}^M \xi_i - \mathbb{E}[\xi]\right| \leq \varepsilon\right] \geq 1 - \delta$, где $\varepsilon = \Delta \sqrt{\frac{1}{2M} \ln \frac{2}{\delta}}$.

В нашем случае:

ξ — это вознаграждение за выбор действия a ,

$\mathbb{E}[\xi] = q_*(a)$,

$M = N_t(a)$ — число выборов к моменту времени t ,

$\frac{1}{M} \sum_{i=1}^M \xi_i = Q_t(a)$.

Заведём закон, который будет отражать убывание δ с течением времени: $\delta = \frac{2}{t^c}$

Тогда с вероятностью не менее $1 - \frac{2}{t^c}$ верно, что

$$\varepsilon = \Delta \sqrt{\frac{C \ln t}{2 N_t(a)}} \geq |q_*(a) - Q_t(a)|, \quad \text{в частности}$$

$$Q_t(a) + \Delta \sqrt{\frac{C}{2}} \sqrt{\frac{\ln t}{N_t(a)}} \geq q_*(a).$$

Многорукий бандит

Существуют модификации UCB, для которых достигается нижняя граница роста ожидаемой цены обучения с той же константой, как и в теореме Lai—Robbins.

Известно, что и для ε -жадной стратегии при правильно подобранной скорости убывания ε также можно получить логарифмический рост ожидаемой цены обучения например, $\varepsilon_k = \frac{1}{k}$ (Auer et al., 2002).

Также и для SoftMax-исследования при правильно подобранной скорости убывания температурного коэффициента τ можно получить логарифмический рост ожидаемой цены обучения (см., например, Cesa-Bianchi et al., 2017).

Байесовские бандиты

Описанные выше методы формирования стратегии для оценки истинных ценностей $q_*(a)$ использовали:


- выборочное среднее $Q_t(a)$,
- размер доверительного интервала, построенного по выборке вознаграждений (UCB).

Следующий шаг — это моделирование распределения вероятностей, которое отражает степень уверенности в местонахождении значения $q_*(a)$.

То есть для каждого $\theta \in \mathbb{R}$ число $p_a(\theta)$ отражает уверенность в том, что $q_*(a) = \theta$.

Здесь $p_a(\theta)$ — это распределение вероятностей.

Такое моделирование основано на байесовском выводе, а соответствующие методы называют **байесовскими бандитами** (англ. Bayesian bandits).



Байесовские бандиты: схема

Зафиксируем действие a . Истинная ценность $q_*(a)$ нам неизвестна.

1. Изначально будем предполагать, что наша степень уверенности имеет некоторое распределение $p_a(\theta)$.

Это распределение называют **априорным** (англ. prior). Например, это может быть равновероятное распределение.

2. Далее, надо выбрать распределение за $p_a(r | \theta)$, которое выражает вероятность получения вознаграждения r за выбор рычага a , при предположении, что истинная ценность за выбор этого действия равна θ .

Для фиксированного r значение $p_a(r | \theta)$, как функцию от θ называют ещё **правдоподобием** (англ. likelihood).

3. Пусть для действия a накоплен опыт взаимодействия агента со средой,

это набор вознаграждений $\mathcal{D}_a = (r_1, \dots, r_M)$.

В рамках нашей модели мы считаем, что вознаграждения получаются независимой выборкой из распределения $p_a(r | \theta)$, тогда правдоподобие данных имеет вид

$$p_a(\mathcal{D}_a | \theta) = \prod_{i=1}^M p(r_i | \theta).$$

Байесовские бандиты: схема

4. Для действия a находим апостериорное распределение (**англ. *aposterior***), которое выражает степень уверенности, что $q_*(a) = \theta$ для разных возможных значений θ при условии накопленного опыта $\mathcal{D}_a$:

тут работает теорема Байеса

$$p_a(\theta | \mathcal{D}_a) = \frac{p_a(\mathcal{D}_a | \theta) p_a(\theta)}{p_a(\mathcal{D}_a)}.$$

На основе распределения $p_a(\theta | \mathcal{D}_a)$ можно по аналогии с ВДГ-стратегией для каждого действия найти среднее μ_a и интервал $[\mu_a - c \sigma_a, \mu_a + c \sigma_a]$, где с высокой вероятностью находится значение $q_*(a)$.

Затем можно выбрать действие с максимальным значением $\mu_a + c \sigma_a$.

Иной подход к формированию стратегии:

выбирать действие a в момент времени t с вероятностью, с которой это действие

является наилучшим с точки зрения наших текущих байесовских распределений

$$\pi_t(a) = \mathbb{P}\left[q_*(a) = \max_{a'} q_*(a) \mid \text{опыт к моменту времени } t\right].$$

Но технически найти эти вероятности сложно. На практике используется **выборка Томпсона**:

из апостериорных распределений $p_a(\theta | \mathcal{D}_a)$ для каждого действия сделаем выборку

$$Q_t(a) \sim p_a(\theta | \mathcal{D}_a).$$

Это текущие оценки ценностей действий. Выбор нового действия делается согласно правилу

$$A_{t+1} = \operatorname{argmax}_{a \in \mathcal{A}} Q_t(a).$$

Байесовские бандиты: схема

В ходе работы байесовских бандитов апостериорные распределения $p_a(\theta | \mathcal{D}_a)$ с накоплением опыта, как правило, становятся более “узкими”, что отражает рост уровня уверенности в оценке истинного среднего значения вознаграждений $q_*(a)$.

Априорное распределение позволяет внедрить в работу метода наши представления о том, как могут быть распределены вознаграждения. Тогда хорошо выбранное априорное распределение может увеличить эффективность работы метода.

Для ряда пар распределений, моделирующих априорное распределение и правдоподобие, можно аналитически найти форму апостериорного распределения.

В том случае, когда априорное и апостериорное распределения принадлежат одному семейству распределений, то пару правдоподобие и априорное распределение называют парой **сопряжённых распределений** (англ. conjugate priors).

Многорукий бандит: выборка Томпсона

Рассмотрим **упрощённую постановку** задачи:

вознаграждений только два типа — 0 или 1 (“неудача” или “успех”),

у каждого рычага своя истинная вероятность получения “успеха” $q_*(a) \in [0, 1]$.

Надо найти самый “успешный” рычаг.

Изначально у агента нет информации об “успешности” рычагов.

Поэтому в качестве априорного распределения $p_a(\theta)$ выберем равномерное распределение на отрезке $[0, 1]$.

$$p_a(\theta) = [\theta \in [0, 1]].$$

Изначально наша степень уверенности в каждом из возможных значений истинной вероятности одинакова.

Далее, выберем действие a и получим вознаграждение $r \in \{0, 1\}$.

Запишем правдоподобие наблюдения вознаграждения r при условии,

что истинное значение ценности $q_*(a)$ было бы равно θ :

$$p_a(r | \theta) = \theta^r (1 - \theta)^{1-r}.$$

Многорукий бандит: выборка Томпсона

Рассмотрим набор данных $\mathcal{D} = \{r_1, \dots, r_M\}$ для действия a . Правдоподобие данных $\mathcal{D}$ имеет вид

$$p_a(\mathcal{D} | \theta) = \prod_{i=1}^M p(r_i | \theta) = \theta^u (1 - \theta)^v,$$

$$\text{где } u = \sum_{i=1}^M r_i \text{ — число успехов, } v = \sum_{i=1}^M (1 - r_i) \text{ — число неудач.}$$

Тогда априорное распределение имеет вид

$$p_a(\theta | \mathcal{D}) = \frac{p_a(\mathcal{D} | \theta) p_a(\theta)}{p(\mathcal{D})} = \frac{\theta^u (1 - \theta)^v}{p(\mathcal{D})}.$$

Таким образом, априорное распределение $p_a(\theta | \mathcal{D})$ — это бета-распределение:

$$f_{\text{Beta}}(\theta; u + 1, v + 1) = \frac{1}{B(u + 1, v + 1)} \theta^u (1 - \theta)^v, \quad \theta \in [0, 1]$$

При этом априорное распределение также является бета-распределением (при $u = v = 0$):

$$p_a(\theta) = f_{\text{Beta}}(\theta; 1, 1) = 1$$

Многорукий бандит: выборка Томпсона

Если добавить ещё одну точку данных $\mathcal{D} \cup \{r\}$, то

$$\begin{aligned} p_i(\theta | \mathcal{D} \cup \{r\}) &= \frac{\theta^{u+r} (1-\theta)^{v+1-r}}{p(\mathcal{D} \cup \{r\})} = \\ &= \frac{\theta^r (1-\theta)^{1-r} p_i(\mathcal{D} | \theta)}{p(\mathcal{D} \cup \{r\})} = \frac{p_i(r | \theta) p_i(\mathcal{D} | \theta)}{p(\mathcal{D} \cup \{r\})} = \\ &= f_{\text{Beta}}(\theta; u+r+1, v+1-r+1). \end{aligned}$$

То есть на каждом новом шаге имеющееся **апостериорное** распределение **можно считать априорным**, что позволяет проводить обновление итеративно.

Надо хранить число успехов и неудач для каждого действия и с каждым новым вознаграждением обновлять значения для соответствующего рычага.

С накоплением данных апостериорные распределения становятся более узкими.

Математическое ожидание бета-распределения $f_{\text{Beta}}(\theta; u+1, v+1)$ равно

$$\frac{u+1}{u+v+2},$$

это значение приближается к истинным вероятностям "успеха" $q_*(a) \in [0, 1]$.

Многорукий бандит: выборка Томпсона

Представим, что мы выбрали каждое действие некоторое количество раз. Для действия $a = i$ есть данные:

u_i число “успехов”, v_i число “неудач”,


$u_i + v_i$ число выборов действия i .

С каждым действием ассоциировано апостериорное распределение, которое равно **бета–распределению** $\text{Beta}(u_i+1, v_i+1)$.

Функция плотности имеет вид:

$$f_{\text{Beta}}(\theta; u_i+1, v_i+1) = \frac{1}{B(u_i+1, v_i+1)} \theta^{u_i} (1-\theta)^{v_i}$$

Out[]=



На каждом временном шаге будем оценивать истинные вероятности $q_*(i)$ с помощью чисел θ_i , полученных реализацией случайной величины с бета-распределением $\text{Beta}(u_i+1, v_i+1)$. Этот факт будем обозначать в виде $\theta_i \sim \text{Beta}(u_i+1, v_i+1)$.

Многорукий бандит: выборка Томпсона

Инициализация: $u_i = v_i = 1, i = 1, \dots, k$.

Повторять:

$\theta_i \sim \text{Beta}(u_i + 1, v_i + 1), i = 1, \dots, k$.

$j \leftarrow \underset{i=1, \dots, k}{\operatorname{argmax}} \theta_i$.


$r \leftarrow \text{bandit}(j)$

$u_j \leftarrow u_j + r$

$v_j \leftarrow v_j + (1 - r)$

Неоднозначности выбора максимума разрешаются случайным образом.

Функция $\text{bandit}(j)$ в псевдокоде означает, что надо выполнить действие j и вернуть вознаграждение, соответствующее сделанному действию. Ниже проиллюстрировано изменение плотностей вероятности бета-распределения $\text{Beta}(u_i + 1, v_i + 1)$ при работе алгоритма в случае 2-х рычагов, у которых истинные вероятности “успеха” равны 0.45 и 0.3.



Известно, что стратегия на основе выборки Томпсона даёт логарифмический рост ожидаемой цены обучения.