

Введение в обучение с подкреплением

## Тема 3: Марковские процессы

Лектор: Кривошеин А.В.

## Вопросы

**Q1.** Какие решения дилеммы исследование-использование предлагает задача о многоруких бандитах?

**Q2.** Что такое марковская среда?

**Q3.** Что такое функции ценности состояний и ценности действий?

## RL: общие понятия


### Суть RL:

научить обучаемого агента предпринимать "хорошие" последовательности действий в ходе взаимодействия со средой для эффективного достижения цели.

**Цель агента:** поиск стратегии поведения, дающей максимальный доход.

### Схема взаимодействия:

обучаемый агент действует в окружающей его среде, среда реагирует на действия агента.



### Обозначения:

$S$  — множество состояний,

$S_t$  — состояние в момент времени  $t$ ,

$\mathcal{A}$  — множество действий,

$A_t$  — действие в момент времени  $t$ ,

$\mathcal{R}$  — множество вознаграждений,

$R_t$  — вознаграждение в момент времени  $t$ .

Взаимодействие агента со средой — это **дискретный случайный процесс**:  $S_0, A_0, R_1, S_1, A_1, \dots$

Конкретная реализация этого процесса — это **траектория** взаимодействия агента со средой.

## Дискретный марковский процесс

Рассмотрим **частный случай** общей постановки задачи RL:

Агента нет, есть только среда, которая меняет своё состояние.

Пусть  $S$  — конечное множество состояний среды, для удобства их можно перенумеровать  $S = \{1, 2, \dots, N\}$ .

**Дискретный процесс смены состояний** — это последовательность случайных величин

$S_0, S_1, \dots, S_t, \dots$ , каждая из которых отвечает за состояние среды в момент времени  $t$ .

Этот процесс называют **марковским** (англ. Markov chain), если

$$\mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t, \dots, S_0 = s_0) = \mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t), \text{ где } s_0, \dots, s_{t+1} \in S.$$

Вероятность перехода среды в новое состояние  $S_{t+1}$  зависит только от текущего состояния  $S_t$  и не зависит от прошлого.

Будем далее рассматривать только **стационарные** марковские процессы, то есть вероятность перехода среды из текущего состояния в новое состояние не меняется со временем.

Для полного описания конечной **стационарной марковской среды** достаточно задать:

матрицу вероятностей  $\{p_{i,j}\}_{i,j \in S}$ , где  $p_{i,j}$  задаёт вероятность перехода среды из состояния  $i$  в состояние  $j$

$$\text{то есть } p_{i,j} = \mathbb{P}(S_{t+1} = j | S_t = i), \quad \sum_{j \in S} p_{i,j} = 1, \text{ для каждого } i \in S.$$

## Дискретный марковский процесс: пример

Для визуализации дискретного марковского процесса удобно использовать **диаграммы**


в виде ориентированного графа с весами:

состояния — это вершины графа, рёбра — это переходы между состояниями, веса — это вероятности переходов.

Рассмотрим простую модель состояния погоды в Санкт-Петербурге. Выделим три состояния погоды:

облачно, пасмурно, дождь.

Переходы из одного состояния в другое отражены на диаграмме.



Матрица вероятностей перехода между состояниями имеет вид

$$P = \begin{pmatrix} 0.4 & 0.3 & 0.3 \\ 0.1 & 0.8 & 0.1 \\ 0.4 & 0.4 & 0.2 \end{pmatrix}.$$

## Марковский процесс вознаграждения

Добавим к марковскому процессу **агента**, который **не совершает действий**,  
но **получает вознаграждения**, наблюдая переходы между состояниями среды.  
Этот процесс называют **марковским процессом вознаграждений** (МПВ, англ. Markov's reward process).

Для задания **конечного МПВ** надо определить:

1. Конечное множество состояний среды  $S$ .

2. **Функцию**  $p : S \times \mathcal{R} \times S \rightarrow [0, 1]$ , которая задаёт модель среды и работу системы вознаграждений, где  $\mathcal{R}$  — это конечное множество возможных вознаграждений.

Её значения — это вероятности перейти из текущего состояния  $S_t = s$  в новое состояние  $S_{t+1} = s'$ , получив вознаграждение  $R_{t+1} = r$ , то есть

$$p(s', r | s) := \mathbb{P}(S_{t+1} = s', R_{t+1} = r | S_t = s),$$

$$\text{где } s, s' \in S, \text{ причём } p(s', r | s) \in [0, 1] \text{ и } \sum_{s' \in S} \sum_{r \in \mathcal{R}} p(s', r | s) = 1.$$

В обозначении  $p(s', r | s)$  нет зависимости от  $t$ , поскольку предполагается **стационарность** модели среды и системы вознаграждений, то есть они не меняются со временем.

3. **Коэффициент обесценивания**  $\gamma \in [0, 1]$  для формирования значений дохода.

## Марковский процесс вознаграждения

На практике функцию  $p : \mathcal{S} \times \mathcal{R} \times \mathcal{S} \rightarrow [0, 1]$  удобнее задать с помощью двух следующих распределений вероятности:

1. вероятность перехода из состояния  $s \in \mathcal{S}$  в состояние  $s' \in \mathcal{S}$ :

$$p(s' | s) := \mathbb{P}(S_{t+1} = s' | S_t = s) = \sum_{r \in \mathcal{R}} p(s', r | s);$$

2. вероятность получить вознаграждение  $r \in \mathcal{R}$  при переходе из состояния  $s \in \mathcal{S}$  в состояние  $s' \in \mathcal{S}$

$$p(r | s, s') := \mathbb{P}(R_{t+1} = r | S_t = s, S_{t+1} = s').$$

Связь между этими условными вероятностями имеет вид

$$p(s', r | s) = p(s' | s) p(r | s, s').$$

На практике  $p(r | s, s')$  часто бывает вырожденным распределением, то есть вознаграждение за переход из состояния  $s \in \mathcal{S}$  в состояние  $s' \in \mathcal{S}$  фиксировано, обозначать его можно  $r(s, s')$ .

Введём также функцию  $r : \mathcal{S} \rightarrow [0, 1]$ , задающую среднее вознаграждение при **переходе из состояния**  $s \in \mathcal{S}$

$$r(s) := \mathbb{E}[R_{t+1} | S_t = s] = \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} r p(s', r | s).$$

## Марковский процесс вознаграждения

**Траекторией эпизодического МПВ** называют набор

$$\tau = (s_0, r_1, s_1, r_2, \dots, r_T, s_T), \quad \text{где либо } s_T \in S_+, \text{ либо } T = T_{\max}.$$

Здесь  $S_+$  множество терминальных состояний, а  $T_{\max}$  — это максимальное число дискретных шагов.

**Траекторией бесконечного МПВ** является последовательность

$$\tau = (s_0, r_1, s_1, r_2, \dots)$$

Эту последовательность можно использовать и для записи траекторий эпизодического МПВ с терминальными состояниями, считая, что при попадании в терминальное состояние среда с вероятностью 1 переходит в это же состояние, а агент получает нулевое вознаграждение.

Траектория является реализацией последовательности случайных величин:  $S_0, R_1, S_1, R_1, \dots$ ,  
при определённом начальном состоянии  $S_0$ .

**Доход** агента  $G_t$  — это взвешенная сумма всех полученных вознаграждений с момента времени  $t$  и до бесконечности,  
то есть это случайная величина вида


$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}.$$

Здесь  $\gamma \in [0, 1]$  — это коэффициент обесценивания. Важно заметить, что в этом обозначении вознаграждения начинают накапливаться с  $R_{t+1}$ .

## МПВ: пример

Доход:  $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$

**Пример.** Рассмотрим пример среды с 5-ю состояниями. Вероятности переходов между состояниями задаются в соответствии со схемой



Вознаграждения **за переход из состояний** определим следующим образом

$$r(s_1) = -1, \quad r(s_5) = 10, \quad r(s_i) = 0 \text{ при } i = 2, 3, 4.$$

Пусть  $\gamma = \frac{1}{2}$ . Для примера найдём доходы для нескольких 4-шаговых эпизодов с различными траекториями:

$$(s_3, s_4, s_5, s_4): \quad G_0 = 0 + 0 \cdot \frac{1}{2} + 10 \cdot \frac{1}{4} = \frac{5}{2},$$

$$(s_3, s_4, s_3, s_2): \quad G_0 = 0 + 0 \cdot \frac{1}{2} + 0 \cdot \frac{1}{4} = 0,$$

$$(s_3, s_2, s_1, s_1): \quad G_0 = 0 + 0 \cdot \frac{1}{2} - 1 \cdot \frac{1}{4} = -\frac{1}{4}.$$

## Вероятностное пространство и случайная величина

Напомним определение и некоторые свойства **математического ожидания случайных величин**.

Формально, сначала определяется **вероятностное пространство**  $(\Omega, \mathcal{A}, \mathbb{P})$ :

$\Omega$  — множество **элементарных событий** (для эпизодического конечного МПВ это всевозможные траектории);

$\mathcal{A}$  — **сигма-алгебра** событий (в нашем случае  $\mathcal{A} = 2^\Omega$ );

$\mathbb{P}$  — **вероятность**, заданная на сигма-алгебре (то есть мера со свойством  $\mathbb{P}(\Omega) = 1$ ).

В случае конечного МПВ вероятность  $\mathbb{P}$  будет задана, если будет **задана вероятность появления каждой траектории**.

Для этого достаточно задать:

вероятности  $\{p(s', r | s)\}_{r \in \mathcal{R}, s, s' \in \mathcal{S}}$  перехода из состояния  $s$  в состояние  $s'$  с вознаграждением  $r$ ,

вероятности  $\{p(s)\}_{s \in \mathcal{S}}$  появления состояний в начальный момент времени  $t = 0$ .

Тогда вероятность появления некоторой траектории  $\tau$  с конкретным набором состояний и вознаграждений вида:

$$\tau = (s_0, r_1, s_1, \dots, r_T, s_T) \text{ будет равна } \mathbb{P}(\tau) = p(s_0) p(s_1, r_1 | s_0) p(s_2, r_2 | s_1) \dots p(s_T, r_T | s_{T-1}).$$

**Случайная величина** — это (измеримое) отображение  $\xi: \Omega \rightarrow \mathbb{R}$ .

В случае конечного МПВ случайные величины задаются на траекториях.

В частности, вознаграждение  $R_t$ , доход  $G_t$ , состояние  $S_t$  — это случайные величины (формально состояния, конечно, не обязаны быть числами, но все состояния можно проиндексировать и заменить состояния индексами).

Например, для траектории  $\tau$  вида  $\tau = (s_0, r_1, s_1, \dots, r_T, s_T)$  эти случайные величины принимают значения:

$$R_t(\tau) = r_t, \quad S_t(\tau) = s_t, \quad G_t(\tau) = r_{t+1} + \gamma r_{t+2} + \dots + \gamma^{T-t-1} r_T.$$

## Математическое ожидание

**Математическое ожидание** — это интеграл от случайной величины по мере  $\mathbb{P}$ :

$$\mathbb{E}[\xi] = \int_{\Omega} \xi d\mathbb{P}.$$

Свойства математического ожидания — это свойства интеграла по мере (линейность, аддитивность и т.д.).

Пусть  $\xi$  — дискретная случайная величина, принимающая конечный набор значений  $x_1, \dots, x_N$  с вероятностями  $p_1, \dots, p_N$ , то есть  $\mathbb{P}(\xi = x_i) = p_i$ . Тогда математическое ожидание  $\xi$  имеет вид

$$\mathbb{E}[\xi] = \sum_{i=1}^N x_i p_i.$$

**Условное математическое ожидание** случайной величины  $\xi$  при условии события  $A \in \mathcal{A}$ :

введём обозначение для события  $B_i = \{\xi = x_i\} = \xi^{-1}(x_i)$ , тогда

$$\mathbb{E}[\xi | A] = \sum_{i=1}^N x_i \mathbb{P}(B_i | A) = \sum_{i=1}^N x_i \frac{\mathbb{P}(B_i \cap A)}{\mathbb{P}(A)} = \frac{1}{\mathbb{P}(A)} \mathbb{E}[\xi \chi_A].$$

## Математическое ожидание: формула полной вероятности

Рассмотрим **разбиение** множества  $\Omega$  на конечное число частей  $B_1, \dots, B_n$ , где

$$\Omega = \bigcup_{i=1}^n B_i, \quad B_i \cap B_j = \emptyset, \quad B_i \in \mathcal{A}.$$

Формула полной вероятности для условного математического ожидания  $\xi$  при условии события  $A$  имеет вид

$$\mathbb{E}[\xi | A] = \sum_{i=1}^n P(B_i | A) \mathbb{E}[\xi | A \cap B_i].$$

В силу определения условного математического ожидания и формулы полной вероятности верны равенства

$$\begin{aligned} \mathbb{E}[\xi | A] &= \frac{1}{\mathbb{P}(A)} \mathbb{E}[\xi \chi_A] = \frac{1}{\mathbb{P}(A)} \mathbb{E}\left[\sum_{i=1}^n \xi \chi_A \chi_{B_i}\right] = \\ &= \sum_{i=1}^n \frac{\mathbb{P}(A \cap B_i)}{\mathbb{P}(A)} \frac{1}{\mathbb{P}(A \cap B_i)} \mathbb{E}[\xi \chi_{A \cap B_i}] = \sum_{i=1}^n P(B_i | A) \mathbb{E}[\xi | A \cap B_i]. \end{aligned}$$

## МПВ: ценности состояний

**Ценность состояния**  $s \in S$  — это ожидаемый доход по всем возможным траекториям при старте из состояния  $s$ :

$$v(s) := \mathbb{E}[G_t | S_t = s] = \mathbb{E}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s\right] = \mathbb{E}[R_{t+1} + \gamma G_{t+1} | S_t = s].$$

Функцию  $v : S \rightarrow \mathbb{R}$  называют функцией ценности состояний или **V-функцией**.

Для эпизодических процессов ценности всех состояний будут конечны. В ином случае необходимо полагать, что  $\gamma < 1$ .

Если возможные вознаграждения  $r \in \mathcal{R}$  ограничены по модулю числом  $M$ . Тогда верна оценка

$$v(s) = \mathbb{E}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s\right] \leq M \mathbb{E}\left[\sum_{k=0}^{\infty} \gamma^k\right] \leq \frac{M}{1-\gamma}.$$

Целый ряд методов RL использует функции ценности для нахождения оптимальных стратегий.

Для вычисления V-функции ценности состояний можно предложить два метода.

**Первый метод** основан на том, чтобы сформировать много траекторий и усреднить доходы, полученные из каждого состояния. Для реализации этого метода модель среды (то есть знание вероятностей перехода между состояниями) не требуется. Не требуется даже, чтобы среда была марковской.

**Второй метод** позволяет получить точное решение, но для этого среда должна быть марковской и модель среды должны быть точно известна. Этот метод основан на том, чтобы сформировать уравнения относительно значений  $v(s)$ .

## МПВ: вычисление ценности состояний

Перепишем определение V-функции в виде уравнения относительно значений  $v(s)$ :

$$\begin{aligned} v(s) &= \mathbb{E}[R_{t+1} + \gamma G_{t+1} | S_t = s] = r(s) + \gamma \mathbb{E}[G_{t+1} | S_t = s] \\ &= r(s) + \gamma \sum_{s' \in S} p(s' | s) v(s'), \quad s \in S. \end{aligned}$$

Последний переход вида

$$\mathbb{E}[G_{t+1} | S_t = s] = \sum_{s' \in S} \mathbb{P}(S_{t+1} = s' | S_t = s) \mathbb{E}[G_{t+1} | S_t = s, S_{t+1} = s'] = \sum_{s' \in S} p(s' | s) v(s').$$

верен в силу **формулы полной вероятности** для условного математического ожидания, где

$$\xi = G_{t+1}, \quad A = \{\tau : S_t = s\}, \quad B_{s'} = \{\tau : S_{t+1} = s'\},$$

и в силу марковости среды (будущее зависит лишь от текущего состояния),

$$\mathbb{E}[G_{t+1} | S_{t+1} = s', S_t = s] = \mathbb{E}[G_{t+1} | S_{t+1} = s'] = v(s').$$

## МПВ: вычисление ценности состояний

Уравнения, которым удовлетворяет V-функция, называют **уравнениями Беллмана**:

$$v(s) = r(s) + \gamma \sum_{s' \in S} p(s' | s) v(s'), \quad s \in S.$$

Их можно записать в матричном виде, положив

$$V = (v(s_1), \dots, v(s_N))^T,$$

$$R = (r(s_1), \dots, r(s_N))^T,$$

$$P = \{p(s' | s)\}_{s, s' \in S}.$$

Тогда

$$V = R + \gamma P V \quad \text{или} \quad (I - \gamma P) V = R.$$

**Точное решение:**  $V = (I - \gamma P)^{-1} R$ .

Для больших размерностей обращение матрицы может быть вычислительно не устойчивым и не эффективным.

**Итеративный способ.** Пусть  $V_0(s) = 0$  для всех  $s$ . Для  $k \in \mathbb{N}$  полагаем,

$$V_{k+1} := R + \gamma P V_k.$$

Решение считается полученным, если для некоторого  $k \in \mathbb{N}$  выполняется оценка  $\|V_{k-1} - V_k\| < \varepsilon$  при заданном  $\varepsilon > 0$ .

## МПВ: вычисление ценности состояний

Гарантия сходимости итеративного метода следует из **принципа сжимающих отображений**.

Определим оператор  $T: \mathbb{R}^N \rightarrow \mathbb{R}^N$  по правилу:

$$T(V) := R + \gamma P V. \quad \text{Итерации имеют вид: } V_{k+1} = T(V_k).$$

Если  $\gamma < 1$ , то **оператор  $T$  является сжимающим** в тах-норме  $\|V\| = \max_s |v(s)|$ .

Действительно, рассмотрим два вектора

$$V = (v(s_1), \dots, v(s_N)) \text{ и } W = (w(s_1), \dots, w(s_N)) \text{ и проведём оценку}$$

$$\|T(V) - T(W)\| \leq \|\gamma P(V - W)\| \leq$$

$$\gamma \max_s \sum_{s' \in S} p(s' | s) |v(s') - w(s')| \leq$$


$$\gamma \|V - W\|, \text{ так как } \sum_{s' \in S} p(s' | s) = 1 \text{ для любого } s.$$

Тогда теорема о сжимающем отображении гарантирует сходимость итеративной последовательности приближений  $V_k$  к неподвижной точке оператора  $T$ , то есть к вектору  $V$  удовлетворяющему равенству  $T(V) = V$ , а это и есть искомое решение.

$$T(V) = R + \gamma P V = V.$$

## МПВ: пример

**Пример.** Рассмотрим пример с 5-ю состояниями, где вероятности смены состояний задаются схемой:




Вознаграждения за переход из состояний определим следующим образом

$$r(s_1) = -1, \quad r(s_5) = 10, \quad r(s_i) = 0 \text{ при } i = 2, 3, 4.$$

Пусть  $\gamma = \frac{1}{2}$ . Найдём  $V$ -функцию. Матрица переходов  $P$  и вектор  $R$  с вознаграждениями имеют вид

$$P = \begin{pmatrix} 0.6 & 0.4 & 0 & 0 & 0 \\ 0.4 & 0.2 & 0.4 & 0 & 0 \\ 0 & 0.4 & 0.2 & 0.4 & 0 \\ 0 & 0 & 0.4 & 0.2 & 0.4 \\ 0 & 0 & 0 & 0.4 & 0.6 \end{pmatrix}, \quad R = (-1, 0, 0, 0, 10)^T.$$

Значения  $V$ -функции продемонстрированы ниже.




## МПВ: схематизация

Возможные траектории при МПВ можно изображать графическими диаграммами в виде дерева.

Корневой вершине соответствует начальное состояние (или текущее состояние) среды.

Из этой вершины исходят рёбра, соответствующие возможным действиям, которые приводят в новые состояния среды, то есть в новые вершины дерева.

Терминальные состояния обычно рисуются в виде квадрата с символом «Т»



Out[-]=


Уравнение Беллмана  $v(s) = r(s) + \gamma \sum_{s' \in S} p(s'|s) v(s')$  также можно изобразить схематически

с помощью **диаграмм обхода** (англ. backup diagram).

Ценность состояния  $s$  равна сумме


среднего вознаграждения за переход из состояния  $s$  и

взвешенной сумме ценностей будущих состояний  $s'$  с весами равными вероятностям перехода в эти состояния.



## МППР

Марковский процесс вознаграждения с агентом, который может совершать действия, влияющие на будущие состояния и вознаграждения называют **марковским процессом принятия решений** (МППР, англ. Markov decision process, MDP).



Чтобы задать **конечный** МППР, необходимо определить набор  $(S, \mathcal{A}, p, \gamma)$ .

1. Конечное множество состояний среды  $S$ .
2. Конечный набор допустимых действий  $\mathcal{A}(s)$  в каждом из состояний  $s \in S$ .
3. Модель среды и способ формирования вознаграждения.

**В детерминированном случае** для любой допустимой пары состояние-действие  $(S_t, A_t) = (s, a)$  в любой момент времени  $t$  определено новое состояние среды  $S_{t+1} = s' \in S$  и вознаграждение  $R_{t+1} = r \in \mathcal{R}$ , где  $\mathcal{R}$  — это конечное множество вознаграждений.

**В стохастическом случае** для любой допустимой пары состояние-действие  $(S_t, A_t) = (s, a)$  в любой момент времени  $t$  определены **вероятности** перехода в одно из новых состояний  $s'$  с получением вознаграждения  $r$ .

4. Коэффициент обесценивания  $\gamma \in [0, 1]$ .

## МППР

Для задания модели среды надо задать функцию  $p : S \times \mathcal{R} \times S \times \mathcal{A} \rightarrow [0, 1]$ , которая определяет вероятности перейти в состояние  $s'$  и получить вознаграждение  $r$ , находясь в состоянии  $s$  и совершив действие  $a$ :

$$p(s', r | s, a) := \mathbb{P}(S_{t+1} = s', R_{t+1} = r \mid S_t = s, A_t = a)$$

для всех возможных  $s, s' \in S, r \in \mathcal{R}, a \in \mathcal{A}$ .

При этом  $\sum_{s' \in S} \sum_{r \in \mathcal{R}} p(s', r | s, a) = 1$  для всех  $s \in S, a \in \mathcal{A}$ .

Эта функция полностью определяет **динамику переходов среды** (англ. transition dynamic).

Будем считать, что среда **стационарна** и со временем её динамика не меняется.

**Траектория** взаимодействия агента со средой в ходе МППР является реализацией последовательности случайных величин:

$$S_0, A_0, R_1, S_1, A_1, R_2, \dots$$

## МППР

Функция  $p(s', r | s, a)$ , задающая модель среды, позволяет найти вероятность перехода между состояниями  $s, s'$  при совершении действия  $a$ :

$$p(s' | s, a) := \mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a) = \sum_{r \in \mathcal{R}} p(s', r | s, a).$$

Эта же функция позволяет найти ожидаемые вознаграждения за переход из состояния  $s$  с действием  $a$ :

$$r(s, a) := \mathbb{E}[R_{t+1} | S_t = s, A_t = a] = \sum_{r \in \mathcal{R}} r \left( \sum_{s' \in \mathcal{S}} p(s', r | s, a) \right),$$

здесь  $\sum_{s' \in \mathcal{S}} p(s', r | s, a)$  задаёт вероятность вознаграждения  $r$  при текущем состоянии  $s$  и действии  $a$ .

Формализм МППР с одной стороны позволяет унифицировано подойти к формулировкам множества различных алгоритмов RL, а также устанавливать сходимость этих алгоритмов.

С другой стороны, он применим к широкому кругу задач RL, то есть задач, описывающих процесс последовательного принятия решений.

## МППР

Цель агента — это **максимизация** дохода путём выбора цепочки "хороших" действий в посещаемых состояниях.

Список “хороших” действий для каждого состояния — это **стратегия** поведения агента.


В стохастическом случае **стратегия** — это **набор вероятностей** выбора действий  $a \in \mathcal{A}$  в каждом из состояний  $s$

$$\pi(a | s) = \mathbb{P}(A_t = a | S_t = s).$$

Для визуализации малых МППР также удобно использовать **диаграммы** аналогично МПВ, в которых действия отображаются также как вершины графа в виде чёрных точек.

Возможные траектории МППР можно изображать графическими диаграммами в виде дерева.

Out[-]=



## Связь МППР и МПВ

Зафиксируем стратегию  $\pi$ . Тогда можно считать, что

**агент просто наблюдает смену состояний и получает вознаграждения.**

При этом, легко найти вероятность смены состояния  $s$  на состояние  $s'$ :

$$P^\pi(s' | s) = \sum_{a \in \mathcal{A}} \pi(a | s) p(s' | s, a) = \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{r \in \mathcal{R}} p(s', r | s, a).$$

Ожидаемые вознаграждения для пары  $(s, a)$  мы нашли на прошлом слайде. Чтобы найти ожидаемое вознаграждение за переход из состояния  $s$ , надо эти вознаграждения усреднить с учётом вероятности выбора действия  $a$ , то есть

$$R^\pi(s) := \mathbb{E}[R_{t+1} | S_t = s] = \sum_{a \in \mathcal{A}} \pi(a | s) \mathbb{E}[R_{t+1} | S_t = s, A_t = a] = \sum_{a \in \mathcal{A}} \pi(a | s) \left( \sum_{r \in \mathcal{R}} r \sum_{s' \in \mathcal{S}} p(s', r | s, a) \right).$$

Поскольку задача агента заключается в поиске “хорошей” стратегии, то может потребоваться вычислять величины вида

$\mathbb{E}[R_{t+1} | S_t = s]$  для различных стратегий. Ясно, что для различных стратегий эти ожидания могут принимать различные значения. Эту зависимость будем отмечать нижним индексом около символа математического ожидания

$$R^\pi(s) = \mathbb{E}_\pi[R_{t+1} | S_t = s].$$

## МППР: V-функция

**Ценность состояния**  $s \in S$  — это ожидаемый доход при старте из состояния  $S_t = s$  и выборе действий по стратегии  $\pi$ :

$$v_\pi(s) := \mathbb{E}_\pi[G_t | S_t = s] = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} | S_t = s].$$

Эта величина выражает насколько хорошо для агента нахождение в данном состоянии с точки зрения длительной перспективы при заданной стратегии поведения  $\pi$ .

Функцию  $v_\pi : S \rightarrow \mathbb{R}$  называют **функцией ценности состояний** (англ. state value function) или **V-функцией**.

Установленная связь МППР и МПВ позволяет сразу получить метод вычисления V-функции для выбранной стратегии  $\pi$ .

Обозначим  $V_\pi := (\dots v_\pi(s) \dots)_{s \in S}^T$ ,  $R := (\dots R^\pi(s) \dots)_{s \in S}^T$ ,  $P := \{P^\pi(s' | s)\}_{s, s' \in S}$ .

Тогда уравнение для V-функции имеет вид:

$$V_\pi = R + \gamma P V_\pi \quad \text{или} \quad v_\pi(s) = R^\pi(s) + \gamma \sum_{s' \in S} P^\pi(s' | s) v_\pi(s'), \quad s \in S.$$

Подставив выражения для  $R^\pi(s)$  и  $P^\pi(s' | s)$ , получим


$$\begin{aligned} v_\pi(s) &= \sum_{a \in \mathcal{A}} \pi(a | s) \left( \sum_{r \in \mathcal{R}} r \sum_{s' \in S} p(s', r | s, a) \right) + \gamma \sum_{s' \in S} \left( \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{r \in \mathcal{R}} p(s', r | s, a) \right) v_\pi(s') = \\ &= \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{s' \in S} \sum_{r \in \mathcal{R}} p(s', r | s, a) (r + \gamma v_\pi(s')). \end{aligned}$$

Это уравнение относительно  $v_\pi(s)$  называют **уравнением Беллмана** для V-функции по стратегии  $\pi$ .

## МППР: диаграмма для уравнения Беллмана

Уравнение Беллмана для V-функции по стратегии  $\pi$  можно визуализировать с помощью диаграммы обхода.

Out[-]=



Чтобы получить значение  $v_\pi(s)$ , надо заглянуть в будущие возможные состояния **на один шаг вперёд** и провести **усреднение** по возможным значениям  $r + \gamma v_\pi(s')$ ,  
с **учётом вероятностей** получения этих значений,  
которые равны произведению вероятности  $\pi(a | s)$  выбора действия  $a$  в состоянии  $s$   
и вероятности  $p(s', r | s, a)$  попадания в новое состояние  $s'$  с вознаграждением  $r$ .

Уравнение Беллмана для V-функции по стратегии  $\pi$  можно также записать более кратко:

$$v_\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) | S_t = s].$$

## МПВ: пример

### Теоретическая задача 1:

1. Доказать, что у матрицы переходов вероятностей  $P$  все собственные числа по модулю не превосходят единицы;
2. Доказать, что у матрицы  $P$  всегда есть хотя бы одно собственное число равное 1.
3. Доказать, что матрица  $I - \gamma P$  обратима при  $\gamma \in (0, 1)$ .

### Теоретическая задача 2:

Найти ценность состояния  $s_0$  для марковского процесса вознаграждений с коэффициентом обесценивания  $\gamma$ , заданного диаграммой:

