Введение в обучение с подкреплением

Тема 3: Марковские процессы

Лектор: Кривошеин А.В.

Вопросы

Q1. Какие решения дилеммы исследование-использование предлагает задача о многоруких бандитах?

Q2. Что такое марковская среда?

Q3. Что такое функции ценности состояний и ценности действий?

RL: общие понятия

Суть RL:

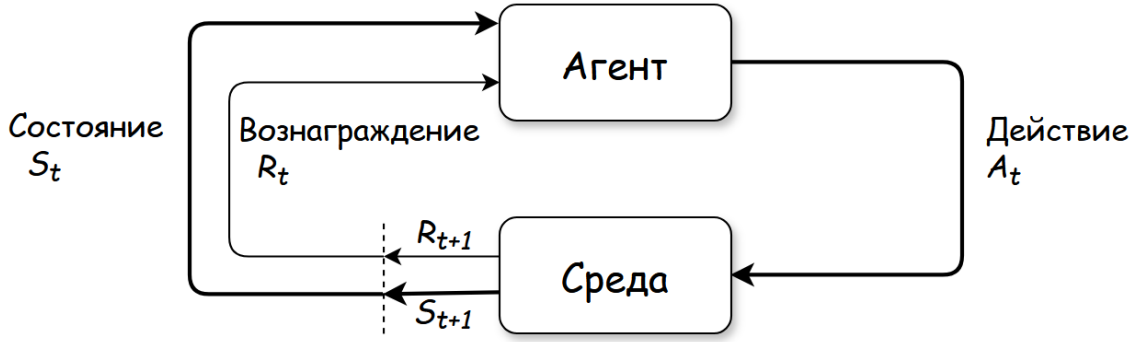
научить обучаемого агента предпринимать "хорошие" последовательности действий в ходе взаимодействия со средой для эффективного достижения цели.

Цель агента: *поиск стратегии поведения, дающей максимальный доход.*

Схема взаимодействия:

обучаемый агент действует в окружающей его среде, среда реагирует на действия агента.

Out[ ]=



Обозначения:

$\mathcal{S}$ — множество состояний, S_t — состояние в момент времени t,

$\mathcal{A}$ — множество действий, A_t — действие в момент времени t,

$\mathcal{R}$ — множество вознаграждений, R_t — вознаграждение в момент времени t.

Взаимодействие агента со средой — это **дискретный случайный процесс**: $S_0, A_0, R_1, S_1, A_1,$ ...

Конкретная реализация этого процесса — это **траектория** взаимодействия агента со средой.

Дискретный марковский процесс

Рассмотрим **частный случай** общей постановки задачи RL:

Агента нет, есть только среда, которая меняет своё состояние.

Пусть $\mathcal{S}$ — конечное множество состояний среды, для удобства их можно перенумеровать $\mathcal{S} = \{1, 2, \ldots, N\}$.

Дискретный процесс смены состояний — это последовательность случайных величин

$S_0, S_1, \ldots, S_t, \ldots$ каждая из которых отвечает за состояние среды в момент времени t.

Этот процесс называют **марковским** (англ. Markov chain), если

$\mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t, \ldots, S_0 = s_0) = \mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t)$, где $s_0, \ldots, s_{t+1} \in \mathcal{S}$.

Вероятность перехода среды в новое состояние s_{t+1} зависит только от текущего состояния s_t и не зависит от прошлого.

Будем далее рассматривать только **стационарные** марковские процессы, то есть вероятность перехода среды из текущего состояния в новое состояние не меняется со временем.

Для полного описания конечной **стационарной марковской среды** достаточность задать:

матрицу вероятностей $\{p_{i,j}\}_{i,j \in \mathcal{S}}$, где $p_{i,j}$ задаёт вероятность перехода среды из состояния i в состояние j

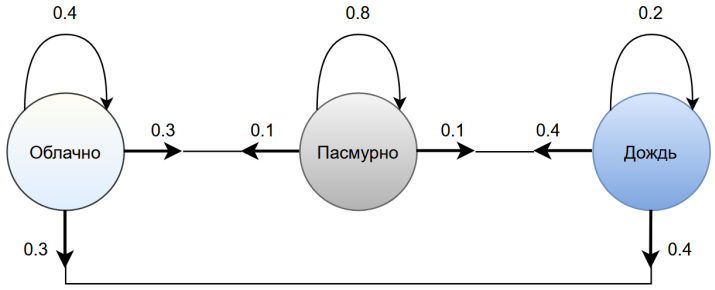
то есть $p_{i,j} = \mathbb{P}(S_{t+1} = j | S_t = i)$, $\sum_{j \in \mathcal{S}} p_{i,j} = 1$, для каждого $i \in \mathcal{S}$.

Дискретный марковский процесс: пример

Для визуализации дискретного марковского процесса удобно использовать **диаграммы**
в виде ориентированного графа с весами:
состояния — это вершины графа, рёбра — это переходы между состояниями, веса — это вероятности переходов.

Рассмотрим простую модель состояния погоды в Санкт-Петербурге. Выделим три состояния погоды:
облачно, пасмурно, дождь.
Переходы из одного состояния в другое отражены на диаграмме.

Out[ ]=



Матрица вероятностей перехода между состояниями имеет вид

$$P = \begin{pmatrix} 0.4 & 0.3 & 0.3 \\ 0.1 & 0.8 & 0.1 \\ 0.4 & 0.4 & 0.2 \end{pmatrix}.$$

Марковский процесс вознаграждения

Добавим к марковскому процессу **агента**, который **не совершает действий**,
но **получает вознаграждения,** наблюдая переходы между состояниями среды.
Этот процесс называют **марковским процессом вознаграждений** (МПВ, англ. Markov's reward process).

Для задания **конечного МПВ** надо определить:

1. Конечное множество состояний среды $\mathcal{S}$.

2. **Функцию $p : \mathcal{S}\times\mathcal{R}\times\mathcal{S} \to [0, 1]$**, которая задаёт модель среды и работу системы вознаграждений, где
$\mathcal{R}$ — это конечное множество возможных вознаграждений.
Её значения — это вероятности перейти из текущего состояния $S_t = s$ в новое состояние $S_{t+1} = s'$, получив вознаграждение $R_{t+1} = r$, то есть

$$p(s', r \mid s) := \mathbb{P}(S_{t+1} = s',\ R_{t+1} = r \mid S_t = s),$$

где $s, s' \in S$, причём $p(s', r \mid s) \in [0, 1]$ и $\sum_{s'\in\mathcal{S}} \sum_{r\in\mathcal{R}} p(s', r \mid s) = 1.$

В обозначении $p(s', r \mid s)$ нет зависимости от t, поскольку предполагается **стационарность** модели среды и системы вознаграждений, то есть они не меняются со временем.

3. **Коэффициент обесценивания** $\gamma \in [0, 1]$ для формирования значений дохода.

Марковский процесс вознаграждения

На практике функцию $p : \mathcal{S}\times\mathcal{R}\times\mathcal{S} \to [0, 1]$ удобнее задать с помощью двух следующих распределений вероятности:

1. вероятность перехода из состояния $s \in \mathcal{S}$ в состояние $s' \in \mathcal{S}$:

$$p(s' \mid s) := \mathbb{P}(S_{t+1} = s' \mid S_t = s) = \sum_{r\in\mathcal{R}} p(s', r \mid s);$$

2. вероятность получить вознаграждение $r \in \mathcal{R}$ при переходе из состояния $s \in \mathcal{S}$ в состояние $s' \in \mathcal{S}$

$$p(r \mid s, s') := \mathbb{P}(R_{t+1} = r \mid S_t = s,\ S_{t+1} = s').$$

Связь между этими условными вероятностями имеет вид

$$p(s', r \mid s) = p(s' \mid s)\ p(r \mid s, s').$$

На практике $p(r \mid s,\ s')$ часто бывает вырожденным распределением, то есть вознаграждение за переход из состояния $s \in \mathcal{S}$ в состояние $s' \in \mathcal{S}$ фиксировано, обозначать его можно $r(s,\ s')$.

Введём также функцию $r : \mathcal{S} \to [0, 1]$, задающую среднее вознаграждение при **переходе из состояния** $s \in \mathcal{S}$

$$r(s) := \mathbb{E}[R_{t+1} \mid S_t = s] = \sum_{s'\in\mathcal{S}} \sum_{r\in\mathcal{R}} r\, p(s', r \mid s).$$

Марковский процесс вознаграждения

Траекторией эпизодического МПВ называют набор

$\tau = (s_0, r_1, s_1, r_2, \ldots r_T, s_T)$, где либо $S_T \in \mathcal{S}_+$, либо $T = T_{\max}$.

Здесь $\mathcal{S}_+$ множество терминальных состояний, а $T_{\max}$ — это максимальное число дискретных шагов.

Траекторией бесконечного МПВ является последовательность

$\tau = (s_0, r_1, s_1, r_2, \ldots)$

Эту последовательность можно использовать и для записи траекторий эпизодического МПВ с терминальными состояниями, считая, что при попадании в терминальное состояние среда с вероятностью 1 переходит в это же состояние, а агент получает нулевое вознаграждение.

Траектория является реализацией последовательности случайных величин: $S_0, R_1, S_1, R_1, \ldots$,
при определённом начальном состоянии S_0.

Доход агента G_t — это взвешенная сумма всех полученных вознаграждений с момента времени t и до бесконечности,
то есть это случайная величина вида

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \ldots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}.$$

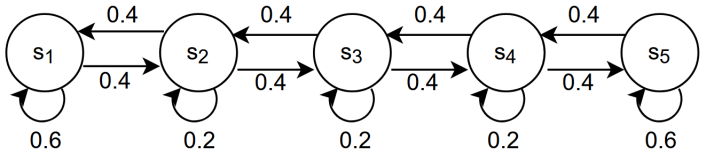
Здесь $\gamma \in [0, 1]$ — это коэффициент обесценивания. Важно заметить, что в этом обозначении вознаграждения начинают накапливаться с R_{t+1}.

МПВ: пример

Доход : $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \ldots$

Пример. Рассмотрим пример среды с 5-ю состояниями. Вероятности переходов между состояниями задаются в соответствии со схемой

Out[•]=



Вознаграждения **за переход из состояний** определим следующим образом

$r(s_1) = -1, \;\; r(s_5) = 10, \;\; r(s_i) = 0$ при $i = 2, 3, 4.$

Пусть $\gamma = \frac{1}{2}$. Для примера найдём доходы для нескольких 4-шаговых эпизодов с различными траекториями:

$$(s_3, s_4, s_5, s_4): \;\; G_0 = 0 + 0 \cdot \frac{1}{2} + 10 \cdot \frac{1}{4} = \frac{5}{2},$$

$$(s_3, s_4, s_3, s_2): \;\; G_0 = 0 + 0 \cdot \frac{1}{2} + 0 \cdot \frac{1}{4} = 0,$$

$$(s_3, s_2, s_1, s_1): \;\; G_0 = 0 + 0 \cdot \frac{1}{2} - 1 \cdot \frac{1}{4} = -\frac{1}{4}.$$

Вероятностное пространство и случайная величина

Напомним определение и некоторые свойства **математического ожидания случайных величин**.

Формально, сначала определяется **вероятностное пространство** $(\Omega, \mathcal{A}, \mathbb{P})$:

Ω — множество **элементарных событий** (для эпизодического конечного МПВ это всевозможные траектории);

$\mathbb{A}$ — **сигма-алгебра** событий (в нашем случае $\mathbb{A} = 2^{\Omega}$);

$\mathbb{P}$ — **вероятность**, заданная на сигма-алгебре (то есть мера со свойством $\mathbb{P}(\Omega) = 1$).

В случае конечного МПВ вероятность $\mathbb{P}$ будет задана, если будет **задана вероятность появления каждой траектории**.

Для этого достаточно задать:

вероятности $\{p(s', r \mid s)\}_{r \in \mathcal{R},\, s, s' \in \mathcal{S}}$ перехода из состояния s в состояние s' с вознаграждением r,

вероятности $\{p(s)\}_{s \in \mathcal{S}}$ появления состояний в начальный момент времени $t = 0$.

Тогда вероятность появления некоторой траектории τ с конкретным набором состояний и вознаграждений вида:

$\tau = (s_0, r_1, s_1, \ \ldots, r_T, s_T)$ будет равна $\mathbb{P}(\tau) = p(s_0)\, p(s_1, r_1 \mid s_0)\, p(s_2, r_2 \mid s_1) \ldots p(s_T, r_T \mid s_{T-1})$.

Случайная величина — это (измеримое) отображение $\xi : \Omega \to \mathbb{R}$.

В случае конечного МПВ случайные величины задаются на траекториях.

В частности, вознаграждение R_t, доход G_t, состояние S_t — это случайные величины (формально состояния, конечно, не обязаны быть числами, но все состояния можно проиндексировать и заменить состояния индексами).

Например, для траектории τ вида $\tau = (s_0, r_1, s_1, \ \ldots, r_T, s_T)$ эти случайные величины принимают значения:

$R_t(\tau) = r_t, \ \ S_t(\tau) = s_t, \ \ G_t(\tau) = r_{t+1} + \gamma\, r_{t+2} + \ldots + \gamma^{T-t-1}\, r_T.$

Математическое ожидание

Математическое ожидание — это интеграл от случайной величины по мере $\mathbb{P}$:

$$\mathbb{E}[\xi] = \int_{\Omega} \xi \, d\,\mathbb{P}.$$

Свойства математического ожидания — это свойства интеграла по мере (линейность, аддитивность и т.д.).

Пусть ξ — дискретная случайная величина, принимающая конечный набор значений $x_1, \ldots, x_N$ с вероятностями $p_1, \ldots, p_N$, то есть $\mathbb{P}(\xi = x_i) = p_i$. Тогда математическое ожидание ξ имеет вид

$$\mathbb{E}[\xi] = \sum_{i=1}^{N} x_i \, p_i.$$

Условное математическое ожидание случайной величины ξ при условии события $A \in \mathbb{A}$:

введём обозначение для события $B_i = \{\xi = x_i\} = \xi^{-1}(x_i)$, тогда

$$\mathbb{E}[\xi \,|\, A] = \sum_{i=1}^{N} x_i \, \mathbb{P}(B_i \,|\, A) = \sum_{i=1}^{N} x_i \, \frac{\mathbb{P}(B_i \bigcap A)}{\mathbb{P}(A)} = \frac{1}{\mathbb{P}(A)} \mathbb{E}[\xi \, \chi_A] \,.$$

Математическое ожидание: формула полной вероятности

Рассмотрим **разбиение** множества Ω на конечное число частей $B_1, \ldots, B_n$, где

$$\Omega = \bigcup_{i=1}^{n} B_i, \quad B_i \cap B_j = \emptyset, \quad B_i \in \mathbb{A}.$$

Формула полной вероятности для условного математического ожидания ξ при условии события A имеет вид

$$\mathbb{E}[\xi \,|\, A] \;=\; \sum_{i=1}^{n} P(B_i \,|\, A)\, \mathbb{E}[\xi \,|\, A \cap B_i].$$

В силу определения условного математического ожидания и формулы полной вероятности верны равенства

$$\mathbb{E}[\xi \,|\, A] \;=\; \frac{1}{\mathbb{P}(A)}\, \mathbb{E}[\xi\, \chi_A] \;=\; \frac{1}{\mathbb{P}(A)}\, \mathbb{E}\Big[\sum_{i=1}^{n} \xi\, \chi_A\, \chi_{B_i}\Big] \;=$$

$$= \sum_{i=1}^{n} \frac{\mathbb{P}(A \cap B_i)}{\mathbb{P}(A)}\, \frac{1}{\mathbb{P}(A \cap B_i)}\, \mathbb{E}[\xi\, \chi_{A \cap B_i}] \;=\; \sum_{i=1}^{n} \mathbb{P}(B_i \,|\, A)\, \mathbb{E}[\xi \,|\, A \cap B_i].$$

МПВ: ценности состояний

Ценность состояния $s \in \mathcal{S}$ — это ожидаемый доход по всем возможным траекториям при старте из состояния s:

$$v(s) := \mathbb{E}[G_t \mid S_t = s] = \mathbb{E}\Big[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,\Big|\, S_t = s\Big] = \mathbb{E}[R_{t+1} + \gamma G_{t+1} \mid S_t = s].$$

Функцию $v : \mathcal{S} \to \mathbb{R}$ называют функцией ценности состояний или **V-функцией**.

Для эпизодических процессов ценности всех состояний будут конечны. В ином случае необходимо полагать, что $\gamma < 1$.

Если возможные вознаграждения $r \in \mathcal{R}$ ограничены по модулю числом M. Тогда верна оценка

$$v(s) = \mathbb{E}\Big[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,\Big|\, S_t = s\Big] \le M\,\mathbb{E}\Big[\sum_{k=0}^{\infty} \gamma^k\Big] \le \frac{M}{1-\gamma}.$$

Целый ряд методов RL использует функции ценности для нахождения оптимальных стратегий.

Для вычисления V-функции ценности состояний можно предложить два метода.

Первый метод основан на том, чтобы сформировать много траекторий и усреднить доходы, полученные из каждого состояния. Для реализации этого метода модель среды (то есть знание вероятностей перехода между состояниями) не требуется. Не требуется даже, чтобы среда была марковской.

Второй метод позволяет получить точное решение, но для этого среда должна быть марковской и модель среды должны быть точно известна. Этот метод основан на том, чтобы сформировать уравнения относительно значений $v(s)$.

МПВ: вычисление ценности состояний

Перепишем определение V-функции в виде уравнения относительно значений $v(s)$:

$$v(s) = \mathbb{E}[R_{t+1} + \gamma G_{t+1} \mid S_t = s] = r(s) + \gamma \mathbb{E}[G_{t+1} \mid S_t = s]$$
$$= r(s) + \gamma \sum_{s' \in S} p(s' \mid s)\, v(s'), \quad s \in \mathcal{S}.$$

Последний переход вида

$$\mathbb{E}[G_{t+1} \mid S_t = s] = \sum_{s' \in S} \mathbb{P}(S_{t+1} = s' \mid S_t = s)\ \mathbb{E}[G_{t+1} \mid S_t = s, S_{t+1} = s'] = \sum_{s' \in S} p(s' \mid s)\, v(s').$$

верен в силу **формулы полной вероятности** для условного математического ожидания, где

$$\xi = G_{t+1}, \quad A = \{\tau : S_t = s\}, \quad B_{s'} = \{\tau : S_{t+1} = s'\},$$

и в силу марковости среды (будущее зависит лишь от текущего состояния),

$$\mathbb{E}[G_{t+1} \mid S_{t+1} = s', S_t = s] = \mathbb{E}[G_{t+1} \mid S_{t+1} = s'] = v(s').$$

МПВ: вычисление ценности состояний

Уравнения, которым удовлетворяет V-функция, называют **уравнениями Беллмана**:

$$v(s) = r(s) + \gamma \sum_{s' \in S} p(s' \mid s)\, v(s'), \quad s \in \mathcal{S}.$$

Их можно записать в матричном виде, положив

$$V = (v(s_1),\ \ldots,\ v(s_N))^T,$$
$$R = (r(s_1),\ \ldots,\ r(s_N))^T,$$
$$P = \{p(s' \mid s)\}_{s,s' \in S}.$$

Тогда

$$V = R + \gamma P V \text{ или } \quad (I - \gamma P) V = R.$$

Точное решение: $V = (I - \gamma P)^{-1} R$.

Для больших размерностей обращение матрицы может быть вычислительно не устойчивым и не эффективным.

Итеративный способ. Пусть $V_0(s) = 0$ для всех s. Для $k \in \mathbb{N}$ полагаем,

$$V_{k+1} := R + \gamma P V_k.$$

Решение считается полученным, если для некоторого $k \in \mathbb{N}$ выполняется оценка $\|V_{k-1} - V_k\| < \varepsilon$ при заданном $\varepsilon > 0$.

МПВ: вычисление ценности состояний

Гарантия сходимости итеративного метода следует из **принципа сжимающих отображений**.

Определим оператор $T : \mathbb{R}^N \to \mathbb{R}^N$ по правилу:

$T(V) := R + \gamma P V$. Итерации имеют вид : $V_{k+1} = T(V_k)$.

Если $\gamma < 1$, то **оператор *T* является сжимающим** в max-норме $\|V\| = \max_s |v(s)|$.

Действительно, рассмотрим два вектора

$V = (v(s_1), \ldots, v(s_N))$ и $W = (w(s_1), \ldots, w(s_N))$ и проведём оценку

$$\|T(V) - T(W)\| \le \|\gamma P(V - W)\| \le$$

$$\gamma \max_s \sum_{s' \in S} p(s' \mid s) \left| v(s') - w(s') \right| \le$$

$\gamma \|V - W\|$, так как $\sum_{s' \in S} p(s' \mid s) = 1$ для любого s.

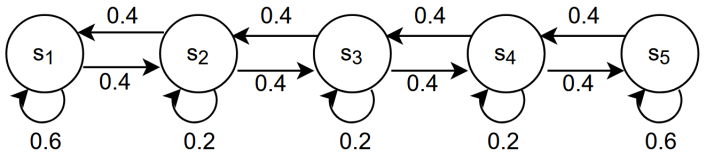
Тогда теорема о сжимающем отображении гарантирует сходимость итеративной последовательности приближений V_k к неподвижной точке оператора T, то есть к вектору V удовлетворяющему равенству $T(V) = V$, а это и есть искомое решение.

$T(V) = R + \gamma P V = V$.

МПВ: пример

Пример. Рассмотрим пример с 5-ю состояниями, где вероятности смены состояний задаются схемой:

Out[ ]=



Вознаграждения за переход из состояний определим следующим образом

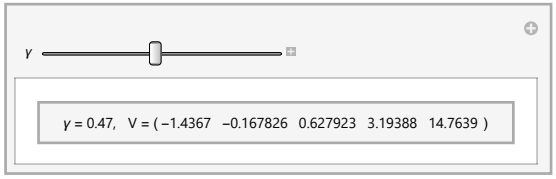
$r(s_1) = -1, \;\; r(s_5) = 10, \;\; r(s_i) = 0$ при $i = 2, 3, 4$.

Пусть $\gamma = \frac{1}{2}$. Найдём V-функцию. Матрица переходов P и вектор R с вознаграждениями имеют вид

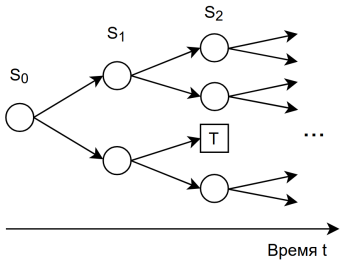
$$P = \begin{pmatrix} 0.6 & 0.4 & 0 & 0 & 0 \\ 0.4 & 0.2 & 0.4 & 0 & 0 \\ 0 & 0.4 & 0.2 & 0.4 & 0 \\ 0 & 0 & 0.4 & 0.2 & 0.4 \\ 0 & 0 & 0 & 0.4 & 0.6 \end{pmatrix}, \quad R = (-1, 0, 0, 0, 10)^T.$$

Значения V-функции продемонстрированы ниже.

Out[ ]=



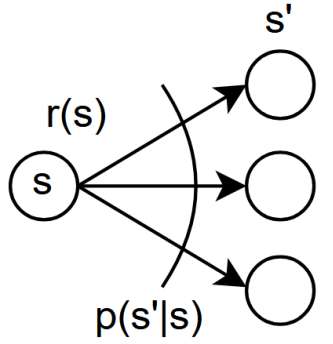
МПВ: схематизация



Возможные траектории при МПВ можно изображать графическими диаграммами в виде дерева.

Корневой вершине соответствует начальное состояние (или текущее состояние) среды.
Из этой вершины исходят рёбра, соответствующие возможным действиям,
которые приводят в новые состояния среды, то есть в новые вершины дерева.
Терминальные состояния обычно рисуются в виде квадрата с символом «T»

Out[ ]=



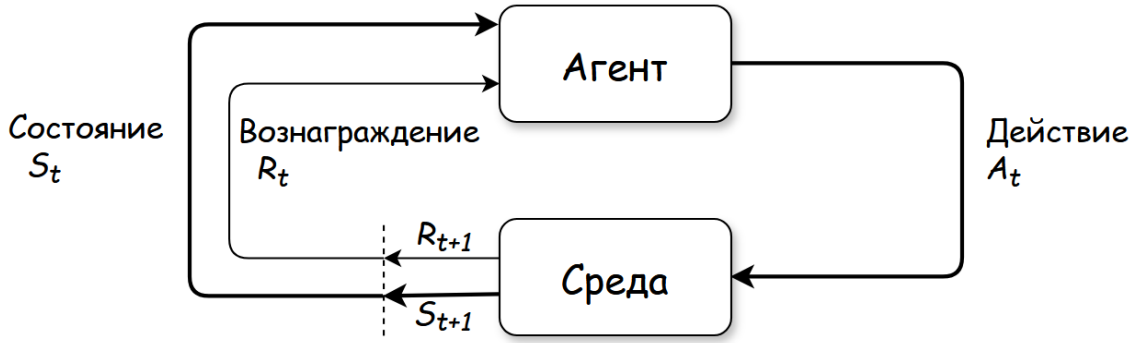
Уравнение Беллмана $v(s) = r(s) + \gamma \sum_{s' \in S} p(s' \mid s)\, v(s')$ также можно изобразить схематически

с помощью **диаграмм обхода** (англ. backup diagram).
Ценность состояния s равна сумме
среднего вознаграждения за переход из состояния s и
взвешенной сумме ценностей будущих состояний s' с весами равными вероятностям
перехода в эти состояния.

МППР

Марковский процесс вознаграждения с агентом, который может совершать действия, влияющие на будущие состояния и вознаграждения называют **марковским процессом принятия решений** (МППР, англ. Markov decision process, MDP).

Out[ ]=



Чтобы задать **конечный** МППР, необходимо определить набор $(\mathcal{S}, \mathcal{A}, p, \gamma)$.

1. Конечное множество состояний среды $\mathcal{S}$.
2. Конечный набор допустимых действий $\mathcal{A}(s)$ в каждом из состояний $s \in \mathcal{S}$.
3. Модель среды и способ формирования вознаграждения.

В детерминированном случае для любой допустимой пары состояние-действие $(S_t, A_t) = (s, a)$ в любой момент времени t определено новое состояние среды $S_{t+1} = s' \in \mathcal{S}$ и вознаграждение $R_{t+1} = r \in \mathcal{R}$, где $\mathcal{R}$ — это конечное множество вознаграждений.

В стохастическом случае для любой допустимой пары состояние-действие $(S_t, A_t) = (s, a)$ в любой момент времени t определены **вероятности** перехода в одно из новых состояний s' с получением вознаграждения r.

4. Коэффициент обесценивания $\gamma \in [0, 1]$.

МППР

Для задания модели среды надо задать функцию $p : S \times \mathcal{R} \times S \times \mathcal{A} : \to [0, 1]$, которая определяет вероятности перейти в состояние s' и получить вознаграждение r, находясь в состоянии s и совершив действие a:

$$p(s', r | s, a) := \mathbb{P}(S_{t+1} = s', R_{t+1} = r \mid S_t = s, A_t = a)$$

для всех возможных $s, s' \in S$, $r \in \mathcal{R}$, $a \in \mathcal{A}$.

При этом $\sum_{s' \in S} \sum_{r \in \mathcal{R}} p(s', r \mid s, a) = 1$ для всех $s \in S$, $a \in \mathcal{A}$.

Эта функция полностью определяет **динамику переходов среды** (англ. transition dynamic).

Будем считать, что среда **стационарна** и со временем её динамика не меняется.

Траектория взаимодействия агента со средой в ходе МППР является реализацией последовательности случайных величин:

$S_0, A_0, R_1, S_1, A_1, R_2, \ldots$

МППР

Функция $p(s', r | s, a)$, задающая модель среды, позволяет найти вероятность перехода между состояниями s, s' при совершении действия a:

$$p(s' | s, a) := \mathbb{P}(S_{t+1} = s' \mid S_t = s, A_t = a) = \sum_{r \in \mathcal{R}} p(s', r | s, a).$$

Эта же функция позволяет найти ожидаемые вознаграждения за переход из состояния s с действием a:

$$r(s, a) := \mathbb{E}[R_{t+1} \mid S_t = s, A_t = a] = \sum_{r \in \mathcal{R}} r \left(\sum_{s' \in S} p(s', r | s, a) \right),$$

здесь $\sum_{s' \in S} p(s', r | s, a)$ задаёт вероятность вознаграждения r при текущем состоянии s и действии a.

Формализм МППР с одной стороны позволяет унифицировано подойти к формулировкам множества различных алгоритмов RL, а также устанавливать сходимость этих алгоритмов.

С другой стороны, он применим к широкому кругу задач RL, то есть задач, описывающих процесс последовательного принятия решений.

МППР

Цель агента — это **максимизация** дохода путём выбора цепочки "хороших" действий в посещаемых состояниях.

Список “хороших” действий для каждого состояния — это **стратегия** поведения агента.

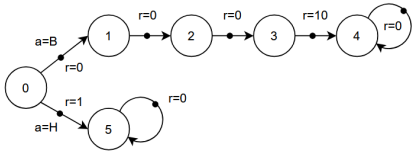
В стохастическом случае **стратегия** — это **набор вероятностей** выбора действий $a \in \mathcal{A}$ в каждом из состояний s

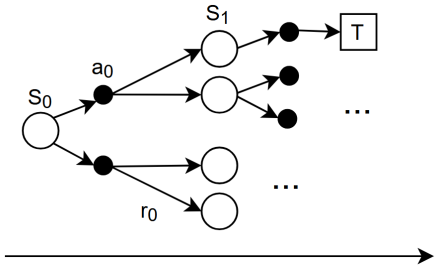
$\pi(a \mid s) = \mathbb{P}(A_t = a \mid S_t = s)$.

Для визуализации малых МППР также удобно использовать **диаграммы** аналогично МПВ, в которых действия отображаются также как вершины графа в виде чёрных точек.

Возможные траектории МППР можно изображать графическими диаграммами в виде дерева.

Out[ ]=





Связь МППР и МПВ

Зафиксируем стратегию π. Тогда можно считать, что

агент просто наблюдает смену состояний и получает вознаграждения.

При этом, легко найти вероятность смены состояния s на состояние s':

$$P^{\pi}(s' \mid s) = \sum_{a \in \mathcal{A}} \pi(a \mid s)\ p(s' \mid s, a) = \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{r \in \mathcal{R}} p(s', r \mid s, a).$$

Ожидаемые вознаграждения для пары $(s,\ a)$ мы нашли на прошлом слайде. Чтобы найти ожидаемое вознаграждение за переход из состояния s, надо эти вознаграждения усреднить с учётом вероятности выбора действия a, то есть

$$R^{\pi}(s) := \mathbb{E}[R_{t+1} \mid S_t = s] = \sum_{a \in \mathcal{A}} \pi(a \mid s)\, \mathbb{E}[R_{t+1} \mid S_t = s, A_t = a] = \sum_{a \in \mathcal{A}} \pi(a \mid s) \left(\sum_{r \in \mathcal{R}} r \sum_{s' \in S} p(s', r \mid s, a) \right).$$

Поскольку задача агента заключается в поиске “хорошей” стратегии, то может потребоваться вычислять величины вида $\mathbb{E}[R_{t+1} \mid S_t = s]$ для различных стратегий. Ясно, что для различных стратегий эти ожидания могут принимать различные значения. Эту зависимость будем отмечать нижним индексом около символа математического ожидания

$$R^{\pi}(s) = \mathbb{E}_{\pi}[R_{t+1} \mid S_t = s].$$

МППР: V-функция

Ценность состояния $s \in \mathcal{S}$ — это ожидаемый доход при старте из состояния $S_t = s$ и выборе действий по стратегии π:

$v_\pi(s) := \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi[R_{t+1} + \gamma\, G_{t+1} \mid S_t = s]$.

Эта величина выражает насколько хорошо для агента нахождение в данном состоянии с точки зрения длительной перспективы при заданной стратегии поведения π.

Функцию $v_\pi : \mathcal{S} \to \mathbb{R}$ называют **функцией ценности состояний** (англ. state value function) или **V-функцией**.

Установленная связь МППР и МПВ позволяет сразу получить метод вычисления V-функции для выбранной стратегии π.

Обозначим $V_\pi := (-v_\pi(s)-)_{s\in\mathcal{S}}^T$, $R := (-R^\pi(s)-)_{s\in\mathcal{S}}^T$, $P := \{P^\pi(s' \mid s)\}_{s,s'\in\mathcal{S}}$.

Тогда уравнение для V-функции имеет вид:

$V_\pi = R + \gamma\, P\, V_\pi$ или $v_\pi(s) = R^\pi(s) + \gamma \sum_{s'\in\mathcal{S}} P^\pi(s' \mid s)\, v_\pi(s'),\ s \in \mathcal{S}$.

Подставив выражения для $R^\pi(s)$ и $P^\pi(s' \mid s)$, получим

$$v_\pi(s) = \sum_{a\in\mathcal{A}} \pi(a \mid s) \left(\sum_{r\in\mathcal{R}} r \sum_{s'\in\mathcal{S}} p(s', r \mid s, a) \right) + \gamma \sum_{s'\in\mathcal{S}} \left(\sum_{a\in\mathcal{A}} \pi(a \mid s) \sum_{r\in\mathcal{R}} p(s', r \mid s, a) \right) v_\pi(s') =$$

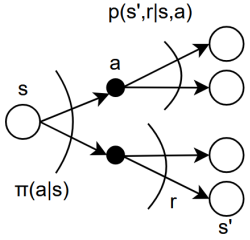
$$\sum_{a\in\mathcal{A}} \pi(a \mid s) \sum_{s'\in\mathcal{S}} \sum_{r\in\mathcal{R}} p(s', r \mid s, a)\, (r + \gamma\, v_\pi(s')).$$

Это уравнение относительно $v_\pi(s)$ называют **уравнением Беллмана** для V-функции по стратегии π.

МППР: диаграмма для уравнения Беллмана

Уравнение Беллмана для V-функции по стратегии π можно визуализировать с помощью диаграммы обхода.

Out[ ]=



Чтобы получить значение $v_\pi(s)$, надо заглянуть в будущие возможные состояния **на один шаг вперёд**

и провести **усреднение** по возможным значениям $r + \gamma\, v_\pi(s')$,

с **учётом вероятностей** получения этих значений,

которые равны произведению вероятности $\pi(a \mid s)$ выбора действия a в состоянии s

и вероятности $p(s', r \mid s, a)$ попадания в новое состояние s' с вознаграждением r.

Уравнение Беллмана для V-функции по стратегии π можно также записать более кратко:

$$v_\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma\, v_\pi(S_{t+1}) \mid S_t = s].$$

МПВ: пример

Теоретическая задача:

1. Доказать, что у матрицы переходов вероятностей P все собственные числа по модулю не превосходят единицы;
2. Доказать, что у матрицы P всегда есть хотя бы одно собственное число равное 1.
3. Доказать, что матрица $I - \gamma P$ обратима при $\gamma \in (0, 1)$.

Упражнение:

Найти ценность состояния s_0 для марковского процесса вознаграждений с коэффициентом обесценивания γ, заданного диаграммой:

Out[ ]=

