

Введение в обучение с подкреплением

Тема 4: Поиск оптимальной стратегии в МППР

Лектор: Кривошеин А.В.

Вопросы

Q1. Что представляет собой марковский процесс **вознаграждений**?

Q2. Что представляет собой марковский процесс **принятия решений**?

Q3. Что такое V-функция и какой вид имеет уравнение Беллмана?

Напоминание о МПВ

Марковский процесс вознаграждений — это марковский процесс, в котором агент наблюдает переходы между состояниями среды и получает вознаграждения, не совершая при этом действий.

Траектория бесконечного МПВ является реализацией последовательности случайных величин

$$S_0, R_1, S_1, R_2, \dots$$

Ценность состояния $v(s)$ — это ожидаемый доход по всем возможным траекториям при старте из состояния s :

$$v(s) := \mathbb{E}[G_t | S_t = s] = \mathbb{E}[R_{t+1} + \gamma G_{t+1} | S_t = s].$$

Уравнение Беллмана для **V-функции**:

$$v(s) = r(s) + \gamma \sum_{s' \in \mathcal{S}} p(s' | s) v(s'), \quad s \in \mathcal{S}.$$

Принцип сжимающих отображений обеспечивает сходимость итеративного метода решения этого уравнения:

$$V_{k+1} := R + \gamma P V_k \quad \text{и} \quad V_k \rightarrow V \quad \text{при} \quad k \rightarrow \infty,$$

$$\text{где } V = (v(s_1), \dots, v(s_N))^T, \quad R = (r(s_1), \dots, r(s_N))^T, \quad P = \{p(s' | s)\}_{s, s' \in \mathcal{S}}.$$

Напоминание о МППР

Марковский процесс принятия решений — это марковский процесс, описывающий взаимодействие агента со средой.

Траектория бесконечного МППР является реализацией последовательности случайных величин

$$S_0, A_0, R_1, S_1, A_1, R_2, \dots$$

Агент действует по **стратегии** $\pi(a | s) = \mathbb{P}(A_t = a | S_t = s)$.

Ценность состояния $v_\pi(s)$ при выбранной стратегии π — это ожидаемый доход при старте из состояния s :

$$v_\pi(s) := \mathbb{E}_\pi[G_t | S_t = s] = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} | S_t = s].$$

Уравнение Беллмана для **V-функции**:

$$v(s) = \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) | S_t = s] = \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{s', r} p(s', r | s, a) (r + \gamma v_\pi(s')).$$

При фиксированной стратегии π можно свести МППР к МПВ. А значит решение уравнения Беллмана можно получить итерационным методом.

МППР: оценка стратегии

Вычисление V -функции $v_\pi(s)$ для стратегии π называют **оценкой стратегии** (англ. policy evaluation).

Зафиксируем начальное приближение $V_0 = \{V_0(s)\}_{s \in \mathcal{S}}$. Итерация имеет вид:

$$V_k(s) := \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, a) (r + \gamma V_{k-1}(s')).$$

Как установлено выше $V_k(s) \rightarrow v_\pi(s)$ при $k \rightarrow +\infty$ для каждого $s \in \mathcal{S}$ при $\gamma < 1$.

На каждой итерации обновляются ценности по всем состояниям на основе значений ценности на прошлом шаге итерации.

Такое обновление называют полным или **синхронным** (англ. synchronous update).

Для организации вычислений требуется два массива V_k и V_{k-1} .

In-place вычисления: есть один массив V , где хранятся текущие оценки ценностей $v_\pi(s)$.

Приближения обновляются в цикле, пробегающем по всем состояниям, по формуле

$$V(s) \leftarrow \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, a) (r + \gamma V(s')).$$

Для каждого состояния s новое значение $V(s)$ вычисляется с помощью массива V , после чего это значение сразу обновляется в массиве V . Такое обновление ещё называют **асинхронным** (англ. asynchronous updates).

Известно, что при **in-place** вычислениях сходимость сохраняется и она более быстрая, так как обновлённые приближения доступны сразу.

МППР: псевдокод для оценки стратегии

Приведём псевдокод для оценки стратегии с помощью итерационного метода и **in-place** вычислениях.

Инициализировать:

число $\theta > 0$ (порог для критерия остановки итераций)

значения $V(s)$ для $s \in S$ произвольным образом

Повторять:

$\Delta \leftarrow 0$

Повторять для каждого $s \in S$:

$v \leftarrow V(s)$

$$V(s) \leftarrow \sum_{a \in \mathcal{A}} \pi(a | s) \sum_{s' \in S} \sum_{r \in \mathcal{R}} p(s', r | s, a) (r + \gamma V(s'))$$

$\Delta \leftarrow \max \{ \Delta, |v - V(s)| \}$

пока не окажется, что $\Delta < \theta$.

В итерационном методе обновление оценки для текущего состояния основаны на текущих оценках следующих состояний. Этот **процесс получения новых оценок на основе других оценок** называется **бутстреппингом** (англ. bootstrapping).

Бутстреп — «ремешки на ботинках», **бутстреппинг** происходит от выражения «потянуть самого себя за ремешки на ботинках и так перелезть через ограду».

Функция ценности состояний $v_\pi(s)$ полезна, чтобы оценить конкретную стратегию π .

Для построения оптимальной стратегии более полезна функция ценности действий или Q-функция.

МППР: Q-функция

Ценность действия $a \in \mathcal{A}$ в состоянии s — это ожидаемый доход при старте из состояния $S_t = s$, выборе действия $A_t = a$ и следовании затем стратегии π :

$$q_\pi(s, a) := \mathbb{E}_\pi[G_t | S_t = s, A_t = a] = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} | S_t = s, A_t = a].$$

Эта величина выражает насколько хорошо для агента в данном состоянии s сделать действие a с точки зрения длительной перспективы при заданной стратегии поведения π .

Функцию $q_\pi : S \times \mathcal{A} \rightarrow \mathbb{R}$ называют **функцией ценности действий** (англ. action value function) или **Q-функцией**.

Установим взаимосвязь между $v_\pi(s)$ и $q_\pi(s, a)$:

$$v_\pi(s) = \mathbb{E}_\pi[G_t | S_t = s] = \sum_{a \in \mathcal{A}} \pi(a | s) \mathbb{E}_\pi[G_t | S_t = s, A_t = a] = \sum_{a \in \mathcal{A}} \pi(a | s) q_\pi(s, a).$$

Если известна модель среды, то можно наоборот выразить $q_\pi(s, a)$ через $v_\pi(s)$ (на следующем слайде).

Если же модели среды нет в наличии, то для агента строить приближения Q-функции полезнее, чем $v_\pi(s)$.

Q-функция даёт прямой ответ на вопрос о том какие действия лучше совершать:

в состоянии s надо делать такое действие a , что значение $q_\pi(s, a)$ максимально, такой выбор ведёт к большему ожидаемому доходу.

В реальных задачах агента сразу обучают Q-функции.

МППР: Q-функция

Выразим $q_\pi(s, a)$ через $v_\pi(s)$.

$$\begin{aligned}
 q_\pi(s, a) &= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} | S_t = s, A_t = a] = \\
 &= \mathbb{E}_\pi[R_{t+1} | S_t = s, A_t = a] + \gamma \mathbb{E}_\pi[G_{t+1} | S_t = s, A_t = a] = \\
 &= \sum_{r \in \mathcal{R}} r \sum_{s' \in \mathcal{S}} p(s', r | s, a) + \gamma \sum_{s' \in \mathcal{S}} p(s' | s, a) \mathbb{E}_\pi[G_{t+1} | S_{t+1} = s'] = \\
 &= \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, a) (r + \gamma v_\pi(s')) = \\
 &= \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, a) \left(r + \gamma \sum_{a' \in \mathcal{A}} \pi(a' | s') q_\pi(s', a') \right).
 \end{aligned}$$

Это **уравнение Беллмана** для Q-функции.

Для итеративного решения надо задать начальные значения $Q_0(s, a)$ для всех $s \in \mathcal{S}$ и $a \in \mathcal{A}$ и использовать формулу

$$Q_{k+1}(s, a) = \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, a) \left(r + \gamma \sum_{a' \in \mathcal{A}} \pi(a' | s') Q_k(s', a') \right).$$

Принцип сжимающих отображений гарантирует сходимость $Q_k(s, a) \rightarrow q_\pi(s, a)$ при $\gamma < 1$.

Процесс вычислений также можно проводить **in-place**.

МППР: диаграмма для уравнения Беллмана

Уравнение Беллмана для Q-функции по стратегии π тоже можно визуализировать с помощью диаграммы обхода.



Чтобы получить значение $q_\pi(s, a)$, надо заглянуть в будущее возможные состояния **на один шаг вперёд**

и провести **усреднение** по возможным значениям $r + \gamma q_\pi(s', a')$,

с **учётом вероятностей** получения этих значений,

которые равны произведению вероятности $p(s', r | s, a)$ попадания в новое состояние s' с вознаграждением r

и вероятности $\pi(a' | s')$ выбора действия a' в состоянии s' .

Уравнение Беллмана для Q-функции по стратегии π можно также записать более кратко:

$$\begin{aligned} q_\pi(s, a) &= \mathbb{E} \left[R_{t+1} + \gamma \sum_{a' \in \mathcal{A}} \pi(a' | S_{t+1}) q_\pi(S_{t+1}, a') \mid S_t = s, A_t = a \right] = \\ &= \mathbb{E} [R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s, A_t = a]. \end{aligned}$$

МППР: улучшение стратегий

Для двух разных стратегий π и π' получатся разные функции ценности $v_\pi(s)$ и $v_{\pi'}(s)$.

Как из этих стратегий выбрать лучшую?

МППР: улучшение стратегий

Будем говорить, что **одна стратегия лучше другой**, если ожидаемый доход при действии по стратегии π' выше при старте из любого состояния:

$$\pi' \geq \pi, \text{ если } v_{\pi'}(s) \geq v_{\pi}(s) \text{ для каждого } s \in S.$$

Для текущей стратегии π всегда можно построить стратегию не хуже. Так как

$$v_{\pi}(s) = \sum_{a \in \mathcal{A}} \pi(a | s) q_{\pi}(s, a),$$

$$\text{то } \min_a q_{\pi}(s, a) \leq v_{\pi}(s) \leq \max_a q_{\pi}(s, a).$$

Пусть $a' = \arg \max_a q_{\pi}(s, a)$. Тогда $q_{\pi}(s, a') \geq v_{\pi}(s)$,

а значит выбор действия a' в состоянии s (и следование стратегии π затем) приведёт большему ожидаемому доходу.

Но как связаны стратегия π и стратегия, при которой во всех встреченных состояниях s мы будем принимать действие a' , а других состояниях действовать по стратегии π . Является ли одна лучше другой?

МППР: улучшение стратегий

Теорема об улучшении стратегии. Пусть $\gamma < 1$, рассмотрим две стратегии π, π' , причём π' детерминирована и $q_\pi(s, \pi'(s)) \geq v_\pi(s)$ для всех $s \in S$.

Тогда стратегия π' не хуже π . То есть $\pi' \geq \pi$ или $v_{\pi'}(s) \geq v_\pi(s)$.

На самом деле, можно установить чуть более общее утверждение.

Общая теорема об улучшении стратегии.

Пусть $\gamma < 1$, рассмотрим две стратегии π, π'

$$\sum_{a \in \mathcal{A}} \pi'(a | s) q_\pi(s, a) \geq v_\pi(s) \quad \text{для всех } s \in S.$$

Тогда стратегия π' не хуже π . То есть $\pi' \geq \pi$ или $v_{\pi'}(s) \geq v_\pi(s)$.

МППР: доказательство теоремы об улучшении стратегий

Доказательство. Рассмотрим цепочку неравенств

$$\begin{aligned} v_{\pi}(s) &\leq q_{\pi}(s, \pi'(s)) = \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, \pi'(s)) (r + \gamma v_{\pi}(s')) \leq \\ &\sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, \pi'(s)) (r + \gamma q_{\pi}(s', \pi'(s'))) \leq \\ &\sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, \pi'(s)) \left(r + \gamma \sum_{r' \in \mathcal{R}} \sum_{s'' \in \mathcal{S}} p(s'', r' | s', \pi'(s')) (r' + \gamma v_{\pi}(s'')) \right) \leq \dots, \end{aligned}$$

где многоточие значит продолжать оценки типа $v_{\pi}(s'') \leq q_{\pi}(s'', \pi'(s''))$ и подстановку выражения для $q_{\pi}(s'', \pi'(s''))$.

Получающиеся суммы не отличаются от итерации уравнения Беллмана для π' :

$$v_{\pi'}(s) = \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r | s, \pi'(s)) (r + \gamma v_{\pi'}(s')) = \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, \pi'(s)) \left(r + \gamma \sum_{r' \in \mathcal{R}} \sum_{s'' \in \mathcal{S}} p(s'', r' | s', \pi'(s')) (r' + \gamma v_{\pi'}(s'')) \right)$$

кроме самого правого слагаемого:

в цепочке неравенств оно имеет вид $v_{\pi}(s^{(n)})$, а в цепочке равенств оно имеет вид $v_{\pi'}(s^{(n)})$, где n число проделанных итераций. У слагаемых этого типа накапливается множитель γ^n . Тогда

$$v_{\pi}(s) - v_{\pi'}(s) \leq \gamma^n \max_{s \in \mathcal{S}} |v_{\pi}(s) - v_{\pi'}(s)| \rightarrow 0 \text{ при } n \rightarrow +\infty \text{ и следовательно } v_{\pi}(s) \leq v_{\pi'}(s). \bullet$$

МППР: улучшение стратегий

В силу доказанной теоремы, чтобы по имеющейся стратегии **построить стратегию лучше**, надо **новую стратегию определять жадным образом относительно** $q_\pi(s, a)$. А именно,

$$\pi'(s) := \arg \max_a q_\pi(s, a). \text{ Эта стратегия будет не хуже, то есть } \pi \leq \pi'.$$

Таким образом, детерминированные стратегии всегда лучше стохастических.

Наилучшую стратегию следует искать среди детерминированных.

Для конечного МППР число детерминированных стратегий конечное число. Тогда в процессе монотонного улучшения стратегий возникнет момент, когда функции ценности по новой стратегии π' и старой стратегии π будут совпадать, то есть

$$v_\pi = v_{\pi'} \text{ или } v_\pi(s) = \max_a q_\pi(s, a).$$

То есть ни в одном состоянии нет действия, которое ещё увеличит ожидаемый доход.

Полученное уравнение — это **уравнение оптимальности Беллмана**:

$$v_\pi(s) = \max_a q_\pi(s, a) = \max_a \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, a) (r + \gamma v_\pi(s')) \text{ для всех } s \in \mathcal{S}.$$

МППР: оператор Беллмана

Введём оператор Беллмана, покажем, что он сжимающий на векторах $V = \{V(s)\}_{s \in S}$.

$$B V(s) := \max_a \sum_{r \in \mathcal{R}} \sum_{s' \in S} p(s', r | s, a) (r + \gamma V(s')).$$

Рассмотрим max-норму и проведём оценку

$$\begin{aligned} \|B V - B W\| &\leq \max_{s \in S} \left| \max_a \sum_{r \in \mathcal{R}} \sum_{s' \in S} p(s', r | s, a) (r + \gamma V(s')) - \max_a \sum_{r \in \mathcal{R}} \sum_{s' \in S} p(s', r | s, a') (r + \gamma W(s')) \right| \leq \\ &\max_{s \in S} \left| \max_a \left(\sum_{r \in \mathcal{R}} \sum_{s' \in S} p(s', r | s, a) (r + \gamma V(s')) - \sum_{r \in \mathcal{R}} \sum_{s' \in S} p(s', r | s, a') (r + \gamma W(s')) \right) \right| \leq \\ &\max_{s \in S} \max_a \sum_{r \in \mathcal{R}} \sum_{s' \in S} p(s', r | s, a) \gamma \max_{s'} |V(s') - W(s')| \leq \gamma \|V - W\|. \end{aligned}$$

Значит уравнение оптимальности Беллмана $B V = V$ имеет единственное решение при $\gamma < 1$.

МППР: оператор Беллмана

В доказательстве используется неравенство : $\left| \max_x f(x) - \max_x g(x) \right| \leq \max_x |f(x) - g(x)|$.

Оно верно по следующим причинам:

верно, что $f(x) \leq |f(x) - g(x)| + g(x)$, а значит

$$\max_x f(x) \leq \max_x (|f(x) - g(x)| + g(x)) \leq \max_x |f(x) - g(x)| + \max_x g(x).$$

Тем самым, $\max_x f(x) - \max_x g(x) \leq \max_x |f(x) - g(x)|$.

Поменяв ролями f и g , получим

$$\max_x g(x) - \max_x f(x) \leq \max_x |f(x) - g(x)|, \text{ что в итоге даёт требуемое неравенство.}$$

МППР: оптимальная стратегия

С одной стороны, решение уравнения оптимальности Беллмана **единственно**. Обозначим это решение за $v_*(s)$.

С другой стороны, процесс улучшения стратегий можно начинать с любой стратегии и гарантировано добратья до стратегии π^* , у которой функция ценности v_{π^*} равна v_* .

Следовательно,

$$v_*(s) \geq v_{\pi}(s) \text{ для всех состояний } s \in S \text{ и стратегий } \pi \text{ или } v_*(s) := \max_{\pi} v_{\pi}(s).$$

V-функцию $v_*(s)$ называют **оптимальной V-функцией**.

Любую стратегию π^* , для которой $v_{\pi^*} = v_*$, называют **оптимальной стратегией**.

Аналогично, можно ввести **оптимальную Q-функцию**. Пусть π^* оптимальная стратегия, тогда из уравнения Беллмана для Q-функции верно, что

$$q_{\pi^*}(s, a) = \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, a) (r + \gamma v_{\pi^*}(s')) \geq \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, a) (r + \gamma v_{\pi}(s)) = q_{\pi}(s, a) \text{ или}$$

$$q_{\pi^*}(s, a) \geq q_{\pi}(s, a) \text{ для любой стратегии } \pi \text{ при всех } s \in \mathcal{S}, a \in \mathcal{A}.$$

Следовательно это и есть оптимальная Q-функция: $q_*(s, a) = q_{\pi^*}(s, a) = \max_{\pi} q_{\pi}(s, a)$.

МППР: Итерация по стратегии

Соображения выше приводят к двум методам поиска оптимальной стратегии.

Способ 1. **Метод итерации по стратегиям.**

Общая идея алгоритма итерации по стратегии:

1. Инициализация начальной стратегии π_0 случайным образом, $i = 0$
2. Повторять, пока стратегия меняется:

Оценить стратегию, то есть найти v_{π_i} по итеративному алгоритму

Улучшить стратегию π_i , выбрав новую стратегию π_{i+1}

$i = i + 1$

$$\pi_0 \xrightarrow{\text{вычислить}} v_{\pi_0} \xrightarrow{\text{улучшить}} \pi_1 \xrightarrow{\text{вычислить}} v_{\pi_1} \dots \longrightarrow \pi_* \longrightarrow v_*.$$

Шаг улучшения заключается в следующем: найти $q_\pi(s, a)$ для всех s и a и определить **новую стратегию π' жадным образом относительно $q_\pi(s, a)$.**

$$\pi'(s) := \operatorname{argmax}_a q_\pi(s, a) = \operatorname{argmax}_a \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, a) (r + \gamma v_\pi(s')).$$

Эта стратегия будет не хуже, то есть $\pi \leq \pi'$.

МППР: Итерация по стратегии, псевдокод

Шаг 1. Инициализировать:

число $\theta > 0$ (порог для критерия остановки итераций);

значения $V(s)$ для $s \in S$ произвольным образом;

значения $\pi(s) \in \mathcal{A}(s)$ произвольным образом для каждого s (начальная детерминированная стратегия).

Шаг 2. Оценка стратегии

Повторять:

$\Delta \leftarrow 0$

Повторять для каждого $s \in S$:

$v \leftarrow V(s)$

$V(s) \leftarrow \sum_{s' \in S} \sum_{r \in \mathcal{R}} p(s', r | s, \pi(s)) (r + \gamma V(s'))$

$\Delta \leftarrow \max \{\Delta, |v - V(s)|\}$

пока не окажется, что $\Delta < \theta$.

Шаг 3. Улучшение стратегии

IsOptimal $\leftarrow$ True

Повторять для каждого $s \in S$:

oldAction $\leftarrow \pi(s)$

bestActions(s) $\leftarrow \arg \max_a \sum_{r \in \mathcal{R}} \sum_{s' \in S} p(s', r | s, a) (r + \gamma V(s'))$ (формируем множество лучших действий)

Если oldAction $\notin$ bestActions(s), то IsOptimal = False.

$\pi(s) \leftarrow a$, где $a \in \text{bestActions}(s)$.

Если IsOptimal == True, то стоп, иначе перейти к Шагу 2.

Особенность псевдокода: при запуске Шага 2 для оценки стратегии, начальной оценкой является приближение функции ценности предыдущей стратегии (на практике это обычно увеличивает скорость сходимости).

МППР: Итерация по ценности

Способ 2. **Метод итерации по ценности.**

Поскольку решение уравнения оптимальности Беллмана — это нахождение неподвижной точки сжимающего оператора, то решение, то есть оптимальную функцию ценности состояний v_* , можно искать итеративным методом.

$$V_{k+1} = B V_k \quad \text{или} \quad V_{k+1}(s) = \max_a \sum_{s' \in S} \sum_{r \in R} p(s', r | s, a) (r + \gamma V_k(s')).$$

Как восстановить оптимальную стратегию π^* ?

Для этого можно вычислить оптимальную функцию ценности действий:

$$q_*(s, a) = \sum_{r \in R} \sum_{s' \in S} p(s', r | s, a) (r + \gamma v_*(s'))$$

и выбирать действия жадно относительно $q_*(s, a)$:

$$\pi^*(s) := \arg \max_a q_*(s, a) = \arg \max_a \sum_{s' \in S} \sum_{r \in R} p(s', r | s, a) (r + \gamma v_*(s')).$$

Общий алгоритм **итерации по ценности:**

1. Инициализировать случайным образом функцию ценности для всех состояний $V_0(s)$.
2. Повторять, пока не получится хорошее приближение:

$$V_{k+1} = B V_k.$$

3. Выделить оптимальную стратегию.

Если изобразить схему алгоритма, аналогичную итерации по стратегии, то она имеет вид

$$V_0 \longrightarrow V_1 \longrightarrow V_2 \longrightarrow \dots \longrightarrow v_*.$$

МППР: Итерация по ценности, псевдокод

Шаг 1. Инициализировать:

число $\theta > 0$ (порог для критерия остановки итераций);

значения $V(s)$ для $s \in S$ произвольным образом;

Шаг 2. Решение уравнения оптимальности Беллмана:

Повторять:

$\Delta \leftarrow 0$

Повторять для каждого $s \in S$:

$v \leftarrow V(s)$

$$V(s) \leftarrow \max_a \sum_{s' \in S} \sum_{r \in \mathcal{R}} p(s', r | s, a) (r + \gamma V(s'))$$

$\Delta \leftarrow \max \{\Delta, |v - V(s)|\}$

пока не окажется, что $\Delta < \theta$.


Шаг 3. Выделение оптимальной стратегии:

$$\pi(s) \leftarrow \operatorname{argmax}_a \sum_{s' \in S} \sum_{r \in \mathcal{R}} p(s', r | s, a) (r + \gamma V(s'))$$

МППР: Итерация по ценности, пример

Рассмотрим МППР, заданный диаграммой. Найти ценности всех состояний при действии по оптимальной стратегии.

$$v_*(s) = \max_a q_*(s, a) = \max_a \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} p(s', r | s, a) (r + \gamma v_*(s')).$$





Out[-]=

Out[-]=

МППР: диаграммы

Итерация по стратегиям означает чередование двух шагов:

1. Оценка: найти истинную функцию ценности v_π для текущей стратегии;
2. Улучшение: выбрать стратегию жадно, относительно текущей функции ценности v_π .



Итерация по ценности в некотором смысле также чередует эти два шага: по сути вычисляется одна итерация оценки Q -функции и при необходимости можно получить улучшенную стратегию жадным выбором действия по этой оценке.

При вычисления in-place чередование шагов происходит ещё чаще: обновляется оценка ценности для одного состояния и сразу улучшается стратегия.


МППР: диаграммы

Обобщённая итерация по стратегиям (ОИС) — это чередование шагов оценки и улучшения стратегии произвольным образом.

Шаг улучшения стратегии жадно выбирает стратегию по текущей функции ценности и делает эту функцию некорректной для новой стратегии.

Шаг обновления оценки для текущей функции ценности приводит к тому, что новая стратегия перестаёт быть жадной.

Однако, совместно эти два процесса находят единственную оптимальную функцию ценности.




МППР: о влиянии коэффициента γ

Коэффициент обесценивания γ не является некоторым гиперпараметром в МППР,

он влияет на оптимальное решение всей задачи.

Рассмотрим МППР, заданный диаграммой.

Out[]=



Выбор действия $a = H$ в состоянии $s = 0$ сразу даёт вознаграждение 1.

Выбор действия $a = B$ в состоянии $s = 0$ даёт вознаграждение $r = 0$, но позволяет в будущем достичь состояния $s = 4$ и получить вознаграждение $r = 10$.

$$Q(s = 0, a = B) = 0 + \gamma \cdot 0 + \gamma^2 \cdot 0 + \gamma^3 \cdot 10 = 10 \gamma^3,$$

$$Q(s = 0, a = H) = 1.$$

Если $\gamma > (0.1)^{1/3}$, то величина $10 \gamma^3$ больше 1, поэтому оптимальным является действие $a = B$.

Если $\gamma < (0.1)^{1/3}$, то величина $10 \gamma^3$ меньше 1, и оптимальным становится действие $a = H$.

Коэффициент дисконтирования γ может полностью изменить оптимальное поведение агента, поэтому это часть определения МППР.

МППР: дополнение

Выше МППР был определён как набор $(\mathcal{S}, \mathcal{A}, p, \gamma)$.

В ряде источников МППР определяют как набор $(\mathcal{S}, \mathcal{A}, p, R, \gamma)$.

Отличие в том, что функция $p : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow [0, 1]$ отвечает за вероятность перехода в состояние s' из состояния s при совершении действия a .

А функция $R : \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{R}$ выдаёт ожидаемое вознаграждение за переход из состояния s при совершении действия a .

$$R(s, a) = \mathbb{E}[R_{t+1} | S_t = s, A_t = a].$$

Из исходного определения легко получить второе определение, так как

$$p(s' | s, a) = \mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a) = \sum_{r \in \mathcal{R}} p(s', r | s, a).$$

$$R(s, a) = \mathbb{E}[R_{t+1} | S_t = s, A_t = a] = \sum_{r \in \mathcal{R}} r \left(\sum_{s' \in \mathcal{S}} p(s', r | s, a) \right).$$

Для обратного перехода не хватает информации о возможном распределении вознаграждений за переход из состояния s при совершении действия a . Однако, все отмеченные выше результаты можно получить и со вторым определением.