Введение в обучение с подкреплением

Тема 6: TD методы

Лектор: Кривошеин А.В.

Особенности TD методов

Методы ДП позволяют агенту заранее просчитать оптимальные действия, максимизирующие доход.

Но для их реализации надо знать модель среды.

Методы МК оценивают совершённые действия в конце эпизода уже после взаимодействия агента со средой.

Оба этих метода не позволяют агенту полноценно **обучаться он-лайн**, то есть обучаться прямо в процессе взаимодействия агента со средой. Для обучения он-лайн, надо решить проблему мгновенной оценки действий и найти возможность искать лучшую стратегию действий по ходу взаимодействия.

Класс методов, решающих эту задачу, называют **методами обучения на основе временных различий** или **TD методами** обучения (англ. Temporal Difference Learning). Эти методы позволяют сделать один шаг по траектории и сразу же обновить оценку сделанного действия.

Напомним, в **методах ДП** для обновления оценки ценности текущего состояния использовалось уравнение Беллмана, которое просматривает возможные состояния и вознаграждения на следующем шаге и проводит усреднение вознаграждений и ценностей новых состояний по всем вероятностям перехода

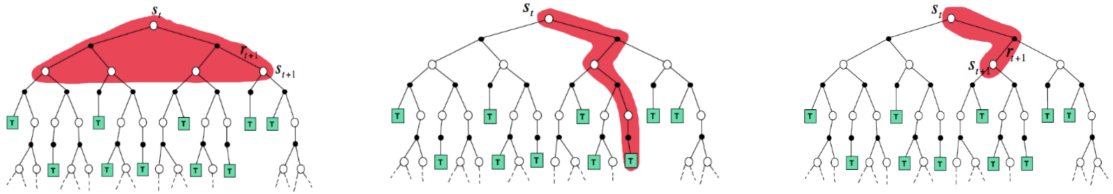
$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{s' \in S} \sum_{r \in \mathcal{R}} p(s', r \mid s, a)\,(r + \gamma\, v_\pi(s')).$$

Причём в итерационных алгоритмах обновление оценки для текущего состояния использует **бутстреппинг**, то есть обновление основано на текущих оценках следующих состояний.

Особенности TD методов

Методы МК основаны на генерации траекторий по выбранной стратегии. Оценка ценности состояния — это усреднение фактически полученных доходов при старте из этого состояния по многим сгенерированным траекториям.

Схематично, эти алгоритмы можно проиллюстрировать так.



Закрашенная область — это область, требуемая для работы алгоритма обучения, чтобы обновить ценности состояний, а значит и стратегию.

Для методов ДП — это все возможные состояния следующего временного шага

Для методов МК — это состояния по траектории от текущего до завершающего.

Для TD методов — это часть траектории от текущего состояния до следующего.

Как и методах МК для оценки функции ценности надо генерировать траектории взаимодействия агента со средой. Но в методах TD не надо ждать конца эпизода, чтобы обновлять оценки и не требуется знание модели среды.

TD: обновление оценок ценности

В методах МК оценка V-функции строится после завершения эпизода: мы считаем фактически полученный доход и используем это число как цель для обновления оценки $V(S_t)$:

$V(S_t) \leftarrow V(S_t) + \alpha(G_t - V(S_t))$.

В TD методах мы не ждём конца эпизода, а обновляем оценку после каждого шага.

Цель для обновления формируется с использованием ближайшего вознаграждения R_{t+1} и оценки ценности нового состояния $V(S_{t+1})$ в виде $R_{t+1} + \gamma\, V(S_{t+1})$.

Правило обновления в этом случае имеет вид

$V(S_t) \leftarrow V(S_t) + \alpha\,(R_{t+1} + \gamma\, V(S_{t+1}) - V(S_t))$.

Разность $\delta_t = R_{t+1} + \gamma\, V(S_{t+1}) - V(S_t)$ между целью обновления и текущей оценкой называют **TD ошибкой**.

Обновление в TD методах основано на ранее полученной оценке, то есть TD метод использует **бутстреппинг**, как и методы ДП.

Напомним, что функция ценности состояний имеет следующий вид

по определению : $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$,

из уравнения Беллмана : $v_\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma\, v_\pi(S_{t+1}) \mid S_t = s]$.

В методах МК целью обновления является фактически полученный доход G_t.

В TD методах целью обновления является сумма полученного вознаграждения и оценка ценности следующего состояния $R_{t+1} + \gamma\, V(S_{t+1})$.

TD: обновление оценок ценности

Использование **бутстреппинга** для обновления оценок:

ДП: да ✓

МК: нет ✗

TD: да ✓

Использование **сэмплирования** для обновления оценок:

ДП: нет ✗

МК: да ✓

TD: да ✓

Использование **модели среды** для обновления оценок:

ДП: да ✓

МК: нет ✗

TD: нет ✗

Для МК, чтобы начать обновление оценок, требуется завершённый эпизод.

TD может обучаться он-лайн на каждом шаге, можно обучаться в неэпизодических средах.

С точки зрения работы с памятью: МК надо хранить весь эпизод, TD обучается с одного перехода.

TD: обновление оценок ценности

Метод TD использует бутстреппинг при обновлении оценки V-функции.

При инициализации V-функции, вообще говоря, $V(s) \neq v_\pi(s)$, то есть начальные оценки никак не связаны с истинными значениями V-функции.

Отсюда, оценка $V(s)$ будет **смещённой** оценкой для значения $v_\pi(s)$. Действительно, после нескольких обновлений ожидаемое значение $V(s)$ равно $\mathbb{E}[R_{t+1} + \gamma V(S_{t+1}) \mid S_t = s]$, что не равно $v_\pi(s)$

(кроме случаев, когда так совпало, что $V(S_{t+1}) = v_\pi(S_{t+1})$).

Оценка $V(s)$ по методу Монте-Карло является **несмещённой**.

С другой стороны, TD оценка будет иметь **малую дисперсию**:

цель обновления зависит только от одного случайного действия и одного перехода.

Оценка по методу МК имеет **большую дисперсию:**

цель обновления зависит от всех сделанных действий и переходов.

TD: оценка стратегии, псевдокод

Приведём алгоритм работы TD метода для оценки функции ценности состояний v_π при фиксированной стратегии π и размере шага обучения α.

---

1. Инициализировать:

значения $V(s) = 0$ для всех $s \in S$ (оценки ценностей состояний)

2. Оценка стратегии

Повторять для каждого эпизода:

Выбрать начальное состояние s

Повторять:

Выбрать действие a по стратегии π в состоянии s

Наблюдать r, s'

Обновить оценку $V(s) \leftarrow V(s) + \alpha\left(r + \gamma V(s') - V(s)\right)$

$s \leftarrow s'$

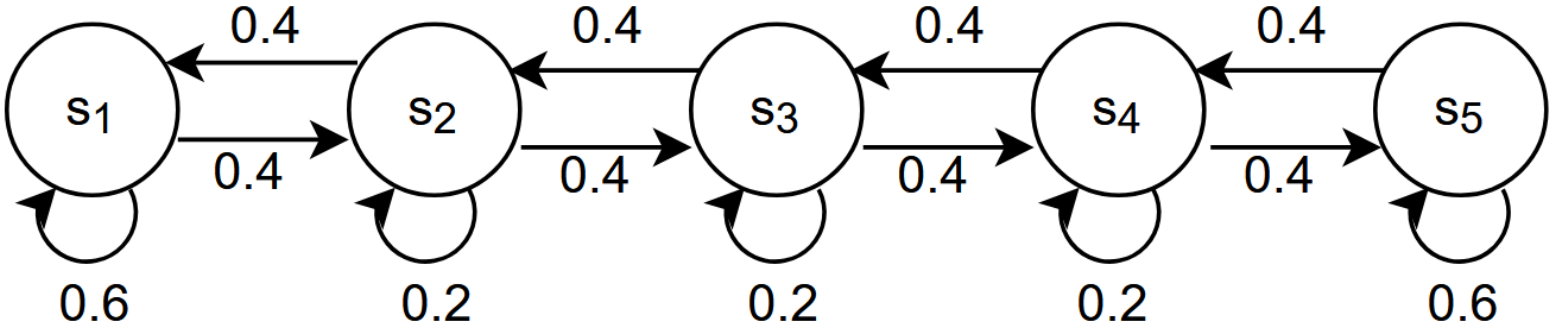
Если s заключительное состояние, то выйти из цикла.

Известно, что оценка ценности состояния $V_n(s)$ (n номер итерации) сходится к истинному значению $v_\pi(s)$, если каждое состояние посещается потенциально бесконечное число раз и размер шага обучения α_n убывает в соответствии с условиями Роббинса-Монро: $\sum_n \alpha_n = \infty, \quad \sum_n \alpha_n^2 < \infty.$

TD: особенность оценки стратегии на примере

Пример. Рассмотрим пример с 5-ю состояниями. Действия: $\{a_0, a_1, a_2\}$ = {влево, вправо, на месте}.
Пусть выбрана некоторая стратегия действий, $\gamma = 1$.

Out[ ]=



Вознаграждения зададим следующим образом: $r(s_2, a_0) = -1$, $r(s_4, a_1) = 10$, $r(s_i, a_j) = 0$ иначе.
Пусть начальные оценки ценностей состояний равны нулю. Рассмотрим некоторую траекторию:

($\boldsymbol{s_3}$, a_1, 0, $\boldsymbol{s_4}$, a_1, 10, $\boldsymbol{s_5}$).

Тогда по методу МК обновлённые оценки будут иметь вид $V(s_3) = 10$, $V(s_4) = 10$,
а по TD методу обновлённые оценки будут иметь вид $V(s_3) = 0$, а $V(s_4) = 10$.

То есть по методу МК информация о финальном вознаграждении сразу доступна для состояния из начала траектории. Для TD методов это не так. Для такой траектории только для состояния s_6 будет по существу обновлена оценка: $V(s_6) = 10$. Однако, для TD методов обновление оценок происходит гораздо чаще, чем для методов МК, что компенсирует эту особенность.

TD: метод SARSA

Рассмотрим метод поиска оптимальной стратегии на основе TD оценки Q-функции по схеме ОИС + ε-мягкие стратегии:

1. **обновляем** оценки Q-функции на основе TD метода, генерируя траектории по текущей стратегии;
2. **улучшаем** стратегию, используя ε-жадный выбор действий относительно текущей Q-функции.

Обновление оценки Q-функции имеет вид:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma\, Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)].$$

Для заключительных состояний полагаем, что $Q(S_T, A_T) = 0$ для всех возможных действий. То есть оценка на последнем шаге будет иметь вид

$$Q(S_{T-1}, A_{T-1}) \leftarrow Q(S_{T-1}, A_{T-1}) + \alpha[R_T - Q(S_{T-1}, A_{T-1})]$$

Чтобы осуществить обновление оценки Q-функции необходимо знать пять значений: S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1}. Причём новое действие A_{t+1} выбирается исходя из текущей стратегии π. Этот алгоритм называют **SARSA** по первым буквам элементов пятерки, определяющей переход из одной пары состояние-действие в другую.

TD: SARSA, псевдокод

Приведём псевдокод алгоритма SARSA для поиска оптимальной стратегии и оптимальной функции ценности действий q_*. Фиксируем размер шага обучения $\alpha > 0$ и $\varepsilon > 0$, а также $\gamma \in (0, 1)$.

---

1. Инициализировать:

значения $Q(s, a) = 0$ для всех состояний $s \in S$ и действий $a \in \mathcal{A}$,

стратегию π определить ε-жадно относительно Q-функции

2. SARSA

Повторять для каждого эпизода:

Выбрать начальное состояние s

Выбрать a следуя ε-жадной стратегии относительно Q-функции

Повторять:

По s, a наблюдать r и s'

Выбрать a' в s', следуя ε-жадной стратегии относительно Q-функции

Обновить оценку $Q(s, a) \leftarrow Q(s, a) + \alpha\left[r + \gamma Q(s', a') - Q(s, a)\right]$

$s \leftarrow s'$, $a \leftarrow a'$

Если s заключительное состояние, то выйти из цикла.

Уменьшить ε

Вернуть стратегию π на основе найденой Q-функции.

TD: SARSA

Теорема. SARSA для конечного МППР сходится к оптимальной Q-функции $q_*(s,\ a)$ при следующих условиях:

1. Итерация по ε-стратегиям является GLIE, то есть ε убывает к нулю с ростом числа итераций;
2. Шаг обучения α_n удовлетворяет условиям Роббинса-Монро: $\sum_n \alpha_n = \infty, \quad \sum_n \alpha_n^2 < \infty$.

Например, можно взять $\alpha_n = \frac{1}{n}$.

SARSA является методом обучения с единой стратегией: траектории генерируются по той стратегии, которую мы оцениваем. То есть при обучении формально нельзя использовать прошлый опыт взаимодействия со средой, так как стратегии изменяются со временем.

Сравнение МК и TD методов

Сходимость оценок V-функции к v_π для методов TD и МК доказана. Но они сходятся по-разному.

Рассмотрим, что происходит при конечном наборе данных: у нас есть K траекторий $\tau_1, \ ..., \ \tau_K$. Обучаться будем на выборке из этого набора траекторий. Пусть есть два состояния A, B и траектории в виде пар (s, r) имеют вид

A, 0, B, 0
B, 1
B, 1
B, 1
B, 1
B, 1
B, 1
B, 0

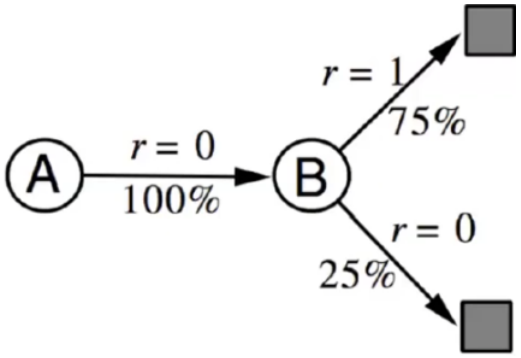
После B мы попадаем в терминальное состояние и взаимодействие завершается.

Для B разумно полагать, что ценность равна 0.75.

Для A разумны два варианта:

1. из A всегда есть переход в B с нулевой наградой, а B уже возможна награда 0 или 1;
2. при старте из A всегда будем попадать в B с нулевой наградой.

Сравнение МК и TD методов



По TD методу:

$V(A) = V(B) = 0.75$

По методу МК:

$V(A) = 0, V(B) = 0.75$

МК сходится к сходится оценкам с наименьшей MSE ошибкой на данных (не используя марковость среды),

TD сходится к оценке максимального правдоподобия на данных

в предположении, что данные возникали из марковской среды (учитываются связи между состояниями).

TD: резюме

Методы TD формируют оценки значений V-функции на основе одношаговых переходов.

Особенности оценки:

1.Оценка $V(s)$ является **смещённой**.

2. Оценка $V(s)$ имеет **малую** дисперсию.

3. Используется **бутстреппинг**, оценка строится из оценок других состояний.

Доказана сходимость к правильным значениям (при слабых условиях).

Режим обучения: **онлайн**, по шагам

Знание динамики среды **не требуется** (англ. model-free).

Out[•]=

Метод	ДП	МК	TD
Требуется модель среды	Да	Нет	Нет
Работа в неэпизодических средах	Да	Нет	Да
Работа в немарковских средах	Нет	Да	Нет
Онлайн обучение	Нет	Нет	Да
Сходимость оценки к V-функции	Да	Да	Да
Оценка является несмещённой	–	Да*	Нет